Повышение квалификации специалистов по информационной безопасности

КОНСПЕКТ ЛЕКЦИИ 4

по курсу
«Методы и принципы проектирования современных защищённых систем. Применение механизмов искусственного интеллекта для анализа данных при построении систем информационной безопасности»

ПОДГОТОВКА ДАННЫХ ДЛЯ АНАЛИТИЧЕСКИХ МОДЕЛЕЙ

Качество данных, признаки, разбиение по времени, дрейф

(2 академических часа)

2026

СОДЕРЖАНИЕ

Введение 4
1 Набор данных для аналитической модели 5
1.1 От записей журнала к объектам набора данных 5
1.2 Особенности данных информационной безопасности 6
1.3 Конвейер подготовки данных 6
2 Качество данных 8
2.1 Типичные проблемы и их влияние на модель 8
2.2 Нормализация и контроль качества 8
2.3 Персональные данные в наборе 9
3 Построение признаков 10
3.1 Виды признаков 10
3.2 Агрегатные признаки: окно и момент отсчёта 10
3.3 Отбор и описание признаков 11
3.3.1 Среднее значение и дисперсия 12
3.3.2 Корреляция и сильно связанные признаки 13
3.3.3 Взаимная информация 14
3.3.4 Важность перестановкой 15
4 Разбиение данных по времени 18
4.1 Утечка данных из будущего 18
4.2 Случайное и временное разбиение 18
4.3 Выборки и зазор между ними 19
4.4 Подготовка данных без утечки 20
5 Метки и шум в разметке 22
5.1 Источники меток 22
5.2 Шум в разметке и способы работы с ним 22
6 Дрейф данных 24

6.1 Виды дрейфа 24
6.2 Обнаружение дрейфа 24
6.3 Реакция на дрейф 25
Заключение 26
Список использованных источников 27
Приложение А Вопросы для самопроверки 28

ВВЕДЕНИЕ

Сл. 1, 2

Лекция посвящена подготовке данных для аналитических моделей, обнаруживающих атаки. **Аналитической моделью** называется программа, которая по признакам наблюдаемого объекта оценивает, относится ли он к атаке. Её параметры подбираются автоматически по размеченным примерам. Качество такой модели определяется не столько выбором алгоритма, сколько качеством данных и корректностью их подготовки.

В лекции рассматриваются устройство набора данных и конвейер его подготовки, контроль качества данных, построение признаков, разбиение данных по времени и защита от утечки информации, особенности разметки и дрейф данных. В примерах используется журнал аутентификации веб-приложения: каждая запись содержит время события, его тип, результат, учётную запись и адрес источника.

1 Набор данных для аналитической модели

1.1 От записей журнала к объектам набора данных

Сл. 3, 4

Таблица 1 — Основные понятия набора данных

Понятие	Что означает	Пример
Набор данных	Таблица, из которой модель получает примеры для обучения и проверки	Все объекты за 56 дней наблюдения
Объект	Одна строка набора: то, о чём модель принимает решение	Адрес источника за 5-минутное окно
Признак	Числовая характеристика объекта, вычисленная по журналу	Число попыток входа в окне
Метка	Известный ответ для объекта: атака или нормальная работа	«атака: подбор пароля»
Выборка	Часть набора данных с определённой ролью	Обучающая, проверочная, тестовая

Сл. 5

Журнал состоит из отдельных записей, тогда как модель принимает решение об **объекте** — такой единице, которую можно описать набором чисел. В качестве объекта выбирают отдельное событие, сеанс пользователя или, чаще всего, **сущность в окне времени**: например, адрес источника за пять минут. Для объекта вычисляются **признаки** — числа, по которым модель отличает атаку от нормальной работы, — и присваивается **метка**. Совокупность таких объектов образует **набор данных** (таблица 1).

Переход от записей журнала к объекту показан на рисунке 1: четыре неудачных попытки входа с одного адреса за пять минут сворачиваются в одну строку набора данных.

Время	Адрес	Учётная запись	Результат
09:00:04	203.0.113.7	anna	неудача
09:00:09	203.0.113.7	anna	неудача
09:00:15	203.0.113.7	anna	неудача
09:00:21	203.0.113.7	anna	неудача
09:02:40	198.51.100.5	boris	успех

→

Признак объекта	Значение
Адрес, окно	203.0.113.7, 09:00–09:05
Число попыток	4
Доля неудач	1,0
Различных учётных записей	1
Метка	атака

Рисунок 1 — От записей журнала к объекту набора данных

Модель обучается на объектах с известными метками, а затем применяется к новым объектам, для которых метки неизвестны. Из этого

следует главное требование ко всей подготовке данных: **всё, что используется при обучении, должно быть доступно и в момент реального применения**. Нарушения этого требования рассматриваются в главе 4.

1.2 Особенности данных информационной безопасности

Сл. 6

Данные информационной безопасности существенно отличаются от данных в типовых задачах машинного обучения. Ещё в 2010 г. Соммер и Пакстон проанализировали причины, по которым применение машинного обучения для обнаружения вторжений сложнее, чем в других областях [1]. Основные особенности сведены в таблицу 2.

Таблица 2 — Особенности данных информационной безопасности

Особенность	В чём проявляется	Следствие для подготовки данных
Крайний дисбаланс классов	Атаки составляют доли процента всех объектов	Метрики и приёмы выбираются с учётом редкости атак; атаки должны попасть во все выборки
Зависимость от времени	События одной атаки и одного сеанса идут подряд и связаны между собой	Выборки нельзя формировать случайно, их разделяют по времени
Дрейф	Поведение пользователей, программ и нарушителей меняется	Качество модели со временем падает; данные нужно контролировать
Шум в разметке	Часть атак не обнаружена и помечена как норма, метки бывают сдвинуты по времени	Разметку проверяют, а оценке качества не доверяют безоговорочно
Противодействие нарушителя	Нарушитель подстраивает действия под известные средства защиты	Модель оценивается на данных, которых нарушитель ещё не видел

1.3 Конвейер подготовки данных

Сл. 7

Подготовка данных выполняется последовательностью этапов, образующих **конвейер** (рисунок 2). Ошибка на любом этапе переходит на все последующие, поэтому каждый этап сопровождается проверкой, а результат конвейера должен воспроизводиться: те же журналы и те же настройки дают тот же набор данных.

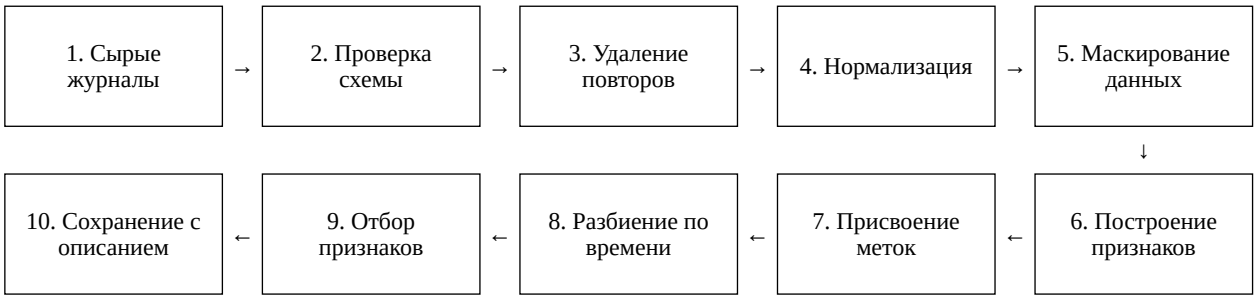


Рисунок 2 — Конвейер подготовки данных

Назначение этапов и получаемые на выходе результаты приведены в таблице 3. Принципиально различаются две группы этапов. Этапы 2–7 не вычисляют параметров по данным и потому выполняются над всем журналом. Этап 9 принимает решения по данным (какие признаки оставить), поэтому выполняется только после разбиения (этап 8) и только по обучающей выборке.

Таблица 3 — Этапы конвейера подготовки данных

Этап	**Что делается**	**Результат**
Проверка схемы	Контролируются обязательные поля, типы и допустимые значения	Записи, пригодные к обработке
Удаление повторов	Убираются записи, доставленные или записанные дважды	Журнал без дублей
Нормализация	Время, адреса и имена типов приводятся к единому виду	Единообразные значения
Маскирование	Персональные данные заменяются псевдонимами	Журнал без раскрытых личных данных
Построение признаков	По записям за окно вычисляются числа, описывающие объект	Таблица объектов и признаков
Присвоение меток	Объектам сопоставляются известные атаки	Таблица с метками
Разбиение по времени	Набор делится на обучающую, проверочную и тестовую выборки	Три выборки с зазорами
Отбор признаков	Признаки отбираются по обучающей выборке, а выбранный набор применяется ко всем	Готовые выборки
Сохранение	Выборки записываются вместе с описанием признаков и параметров конвейера	Воспроизводимый набор данных

2 Качество данных

2.1 Типичные проблемы и их влияние на модель

Сл. 8, 9

Модель способна обучиться только тому, что есть в данных, включая их дефекты. Типичные проблемы журналов и их влияние на модель приведены в таблице 4.

Таблица 4 — Типичные проблемы качества данных

Проблема	Как проявляется в журнале	Влияние на модель
Пропуски	В записи нет адреса источника или клиентского приложения	Смещение оценок, ошибки при вычислении признаков
Повторы	Одна запись попала в журнал дважды при повторной доставке	Завышенное качество: копия записи оказывается в разных выборках
Разрывы потока	Источник часами не присылал записей из-за сбоя	Отсутствие записей принимается за отсутствие событий, искажаются признаки по окнам
Разные форматы	Время записано в разных часовых поясах, адреса в разных формах	Ошибки разбора, неверный порядок событий
Неверные метки	Атака не размечена или размечена не в то время	Модель учится на ошибочных примерах
Персональные данные	В записях содержатся имена, адреса электронной почты	Риск утечки при хранении и передаче набора данных

Сл. 10

Особого внимания заслуживают разрывы потока. Для человека отсутствие записей за определённый час может означать тихий период, а для модели — нормальную работу. Если в этот час шла атака, но журнал не велся, ошибка попадёт в обучающую выборку как «норма».

2.2 Нормализация и контроль качества

Сл. 11

Контроль качества выполняется автоматическими проверками, которые встраиваются в конвейер и останавливают его при нарушении. Основные проверки приведены в таблице 5.

Таблица 5 — Проверки качества данных

Проверка	Как выполняется	Что предотвращает
Схема записи	Есть все обязательные поля, типы и допустимые значения соответствуют описанию (результат — только «успех» или «неудача»)	Сбой или тихое искажение признаков
Повторы	Сравнение по уникальному номеру записи или по сочетанию времени, источника, типа события и субъекта	Копии записей в разных выборках
Непрерывность потока	Число записей по часам сравнивается с ожидаемым; нулевые и аномально малые значения помечаются	Ложные «тихие» периоды
Единообразие	Время приводится к единому часовому поясу в формате ISO 8601, адреса к одной форме записи, имена типов к одному регистру	Ошибки разбора и порядка событий
Порядок времени	Отметки времени не уходят в будущее и не выходят за период наблюдения	Неверные границы выборок

2.3 Персональные данные в наборе

Сл. 12

Набор данных живёт дольше журнала и обычно доступен более широкому кругу специалистов, поэтому персональные данные маскируют до построения признаков. Идентификаторы пользователей заменяют псевдонимами, вычисленными с секретным ключом, а адреса электронной почты, номера документов и платёжных карт исключают. Важно, чтобы псевдоним одного пользователя был постоянным: тогда по нему по-прежнему можно считать агрегатные признаки, но личность без ключа установить нельзя.

3 Построение признаков

3.1 Виды признаков

Сл. 13, 14

Признаки различают по тому, какие данные используются при вычислении (таблица 6). От выбора признаков зависит, сможет ли модель отличить атаку от нормальной работы, поэтому признаки подбирают под конкретную атаку.

Таблица 6 — Виды признаков

Вид	Что считается	Примеры	Ограничение
Событийные	Характеристика одной записи	Час суток, нерабочее время, вид клиентского приложения, причина неудачи	Не видят связи между событиями
Агрегатные	Статистика по записям сущности за окно	Число попыток, доля неудач, число различных учётных записей, средний интервал между попытками	Зависят от длины окна
Статистические	Отклонение от обычного уровня сущности	Число попыток по сравнению со средним за 7 дней, редкость типа события	Требуют истории, медленно адаптируются

3.2 Агрегатные признаки: окно и момент отсчёта

Сл. 15

Для атак, состоящих из серии действий, главными оказываются агрегатные признаки. Они вычисляются для **сущности** (адреса, учётной записи, сеанса) по записям за **окно** — интервал времени заданной длины. Каждый объект привязан к **моменту отсчёта** — времени, на которое строится его описание и в которое модель будет принимать решение. Окно заканчивается в момент отсчёта, а события после него при вычислении признаков не используются: в реальной работе их ещё не существует (рисунок 3).

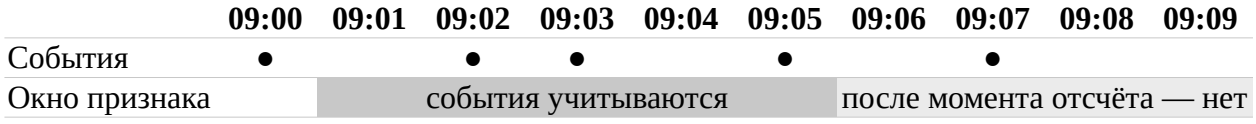


Рисунок 3 — Окно признака в 5 минут и момент отсчёта 09:06: события после него не используются

Сл. 16

Набор признаков подбирают так, чтобы он различал разные атаки и нормальную работу. В таблице 7 приведены четыре объекта: подбор пароля к одной учётной записи, распыление паролей (один пароль против многих

учётных записей), нормальные пользователи за общим адресом и одиночный пользователь.

Таблица 7 — Агрегатные признаки четырёх объектов

Объект (окно 5 минут)	**Попыток**	**Доля неудач**	**Различных учётных записей**	**Метка**
Адрес A: пользователь ввёл пароль с ошибкой	2	0,50	1	норма
Адрес B: подбор пароля к одной учётной записи	8	1,00	1	атака
Адрес C: распыление паролей	9	1,00	9	атака
Адрес D: офис с общим адресом	40	0,08	25	норма

Ни один признак в отдельности не разделяет все четыре случая. Число попыток одинаково велико у атаки C и у нормального офиса D; различает их доля неудач. Доля неудач одинакова у B и C; различает их число разных учётных записей. Поэтому признаки подбирают набором и проверяют на разных видах атак и нормальной работы.

3.3 Отбор и описание признаков

Сл. 17

Избыточные признаки повышают риск переобучения, замедляют обучение и применение модели. **Переобучением** называется состояние, при котором модель хорошо запоминает обучающие примеры, но плохо работает на новых данных. Чем больше в наборе лишних признаков, тем больше у модели возможностей «зацепиться» за случайные совпадения. Поэтому из набора убирают признаки, которые дублируют друг друга, ничего не различают или не помогают отличить атаку от нормальной работы. Распространённые способы отбора приведены в таблице 8; каждый из них подробно разобран ниже. Решение о том, какие признаки оставить, принимается только по обучающей выборке (подраздел 4.4).

Таблица 8 — Способы отбора признаков

Способ	Вопрос, на который он отвечает	Что делают
Удаление сильно связанных признаков	Не повторяют ли два признака друг друга?	Из пары остаётся один
Удаление почти постоянных признаков	Различает ли признак хоть какие-то объекты?	Постоянный признак удаляется
Взаимная информация	Насколько знание признака помогает угадать метку?	Остаются признаки с наибольшей информацией
Важность перестановкой	Насколько ухудшится модель, если лишить её признака?	Остаются признаки, без которых качество падает

3.3.1 Среднее значение и дисперсия

Для описания признака вводятся два числа. **Среднее значение** — сумма значений, делённая на их число. **Дисперсия** — среднее значение квадрата отклонения от среднего; она показывает, насколько сильно значения признака «разбросаны» вокруг среднего:

$$\mathrm{Disp} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2. \tag{1}$$

Корень из дисперсии называют **стандартным отклонением**; оно измеряется в тех же единицах, что и сам признак. Рассмотрим признак «число попыток входа за окно» для восьми объектов: 2, 4, 4, 4, 5, 5, 7, 9. Среднее равно $\frac{2+4+4+4+5+5+7+9}{8} = 5$. Отклонения от среднего: $-3, -1, -1, -1, 0, 0, 2, 4$; их квадраты: $9, 1, 1, 1, 0, 0, 4, 16$, сумма равна 32. Дисперсия равна $\frac{32}{8} = 4$, стандартное отклонение равно 2.

Если же у всех восьми объектов признак равен одному числу, например 3, то среднее равно 3, все отклонения нулевые и дисперсия равна нулю. Такой **постоянный признак** не различает ни одну пару объектов, поэтому не может помочь отличить атаку от нормальной работы и подлежит удалению. На практике удаляют и признаки, дисперсия которых близка к нулю: они почти ничего не различают, а шум в них легко принять за закономерность. Следует помнить, что дисперсия зависит от единиц измерения: признак в миллисекундах имеет дисперсию в миллион раз большую, чем тот же признак в секундах, поэтому порог для дисперсии выбирают для каждого признака отдельно или сравнивают признаки после приведения к одному масштабу.

3.3.2 Корреляция и сильно связанные признаки

Два признака называются **сильно связанными**, если по значению одного можно довольно точно предсказать значение другого. Например, число неудачных попыток входа почти пропорционально общему числу попыток: чем больше попыток, тем больше и неудач. Модель, которой даны оба признака, получает в основном одну и ту же информацию дважды, а набор признаков при этом становится длиннее и неустойчивее.

Силу линейной связи измеряют **коэффициентом корреляции** r. Он рассчитывается в три шага. Сначала для каждого объекта находят отклонения обоих признаков от их средних. Затем вычисляют **ковариацию** — среднее значение произведения этих отклонений. Наконец, ковариацию делят на произведение стандартных отклонений:

$$r = \frac{\operatorname{Cov}(x, y)}{\sigma_x \cdot \sigma_y}, \quad \operatorname{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y}). \tag{2}$$

Деление на стандартные отклонения делает коэффициент безразмерным и ограничивает его значения отрезком от -1 до $+1$. Расчёт на примере пяти объектов приведён в таблице 9: признак x — число попыток, признак y — число неудач.

Таблица 9 — Расчёт коэффициента корреляции

Объект	x	y	$x - \overline{x}$	$y - \overline{y}$	**Произведение**
1	2	2	−4	−3,6	14,4
2	4	3	−2	−2,6	5,2
3	6	6	0	0,4	0
4	8	7	2	1,4	2,8
5	10	10	4	4,4	17,6
Итого	$\overline{x} = 6$	$\overline{y} = 5,6$	—	—	40

Ковариация равна $\frac{40}{5} = 8$. Стандартное отклонение x равно $\sqrt{\frac{40}{5}} \approx 2,83$, стандартное отклонение y — примерно 2,87. Коэффициент корреляции равен $\frac{8}{2{,}83 \cdot 2{,}87} \approx 0,985$, то есть связь очень сильная. Для оценки значений коэффициента удобно ориентироваться на таблицу 10.

Таблица 10 — Как читать коэффициент корреляции

Значение r	**Смысл**	**Пример**
Около +1	Признаки растут вместе	Число попыток и число неудач
Около 0	Линейной связи нет	Число попыток и час суток
Около −1	Один растёт, другой убывает	Доля успешных входов и доля неудач

На практике из пары признаков, у которых модуль r превышает порог (часто берут 0,95), оставляют один, обычно тот, который проще вычислить или легче объяснить. Важно учитывать два ограничения. Корреляция измеряет только **линейную** связь: признаки, связанные сложной зависимостью, могут иметь коэффициент около нуля. Кроме того, корреляция между двумя признаками ничего не говорит об их связи с меткой; для этого служат способы, описанные ниже.

3.3.3 Взаимная информация

Взаимная информация отвечает на вопрос: насколько знание значения признака уменьшает неопределённость относительно метки. Она измеряется в битах и равна нулю, если признак и метка независимы. В отличие от корреляции, она улавливает любые зависимости, в том числе нелинейные. Для расчёта значения признака разбивают на группы и по числу объектов в каждой группе вычисляют сумму

$$I = \sum_{a,b} p(a,b) \log_2 \frac{p(a,b)}{p(a)p(b)}, \tag{3}$$

где a — группа признака, b — метка, $p(a,b)$ — доля объектов, одновременно относящихся к группе и метке, а $p(a)$ и $p(b)$ — доли объектов группы и метки по отдельности. Если признак не влияет на метку, то $p(a,b) = p(a)p(b)$, логарифм равен нулю и вся сумма равна нулю.

Рассмотрим сто объектов и признак «доля неудач высокая» (группы «да» и «нет»). Распределение объектов приведено в таблице 11.

Таблица 11 — Распределение объектов для расчёта взаимной информации

Группа признака	**Атака**	**Норма**	**Всего**
Доля неудач высокая	18	2	20
Доля неудач низкая	2	78	80
Всего	20	80	100

Доли атак и нормы в целом равны 0,2 и 0,8, а групп «высокая» и «низкая» — 0,2 и 0,8. Если бы признак ничего не значил, объекты распределились бы пропорционально: в ячейке «высокая и атака» оказалось бы $0,2 \cdot 0,2 = 0,04$ всех объектов, то есть четыре. На деле их 18, то есть 0,18. Вклад каждой ячейки показан в таблице 12; сумма вкладов, то есть взаимная информация, равна примерно 0,49 бита.

Таблица 12 — Вклады ячеек во взаимную информацию

Ячейка	**Доля** $p(a,b)$	**Ожидалось** $p(a)p(b)$	**Вклад**
Высокая и атака	0,18	0,04	+0,391
Высокая и норма	0,02	0,16	−0,060
Низкая и атака	0,02	0,16	−0,060
Низкая и норма	0,78	0,64	+0,223
Итого	1,00	1,00	0,493

Для сравнения: максимально возможное значение равно неопределённости самой метки, то есть для долей 0,2 и 0,8 примерно 0,72 бита. Полученные 0,49 бита означают, что признак устраняет заметную часть неопределённости. У признака, не связанного с меткой (например, 4 и 16 объектов в первой строке, 16 и 64 во второй при тех же долях 20 % и 80 %), взаимная информация равна нулю. По значениям взаимной информации признаки упорядочивают и оставляют те, у которых она наибольшая. Недостаток способа состоит в том, что он оценивает каждый признак отдельно: два одинаково информативных, но дублирующих друг друга признака получат одинаково высокие оценки.

3.3.4 Важность перестановкой

Предыдущие способы оценивают признак независимо от модели. **Важность перестановкой** отвечает на практический вопрос: насколько ухудшится **обученная** модель, если лишить её этого признака. Процедура состоит из четырёх шагов:

1. обученная модель применяется к проверочной выборке и измеряется качество — например, доля верных ответов;
2. значения одного признака случайно перемешиваются между объектами (остальные признаки и метки остаются на месте), так что связь признака с меткой разрушается;

3. модель снова применяется к полученной таблице и измеряется качество;
4. важность признака равна разности качества до и после перемешивания; шаги 2–3 повторяют для каждого признака.

Пример приведён в таблице 13. Для десяти объектов проверочной выборки модель считает объект атакой, если доля неудач превышает 0,5; число попыток она не использует. До перестановки модель отвечает верно на всех десяти объектах, то есть с долей верных ответов 1,0. Если значения доли неудач переставить, то модель почти перестаёт угадывать: верных ответов остаётся четыре из десяти. Если же переставить значения числа попыток, ответы модели не меняются.

Таблица 13 — Пример важности перестановкой

Признак, значения которого перемешаны	**Доля верных ответов до**	**После**	**Важность**
Доля неудач	1,0	0,4	0,6
Число попыток	1,0	1,0	0,0

Вывод: без доли неудач модель теряет большую часть качества, и признак необходим; число попыток модель не использует, и его можно удалить без потери качества. Преимущество способа в том, что он учитывает реальную модель и взаимодействие признаков. Ограничения следующие. Перестановка измеряется на проверочной, а не на обучающей выборке, иначе оценка получится завышенной. Если два признака дублируют друг друга, перестановка любого из них мало ухудшит модель, так как второй признак сохраняет информацию, и оба получат заниженную важность. Результат слегка меняется от запуска к запуску, поэтому перестановку повторяют несколько раз и усредняют.

Для каждого признака ведётся **описание** — по нему другой специалист должен вычислить признак так же и понять его границы. Пример описания приведён в таблице 14.

Таблица 14 — Пример описания признака

Поле	Содержание
Имя	`failure_share_5m`
Описание	Доля неудачных попыток входа среди всех попыток за 5 минут
Тип и границы	Число от 0 до 1
Источник	Поле `outcome` записей с типом события `auth.login`
Сущность и окно	Адрес источника, 5 минут до момента отсчёта
Особые случаи	При нуле попыток не определён; заменяется значением 0

4 Разбиение данных по времени

4.1 Утечка данных из будущего

Сл. 18, 19

Утечкой данных называется ситуация, при которой модель при обучении или настройке получает сведения, которых не будет в момент реального применения. Утечка приводит к завышенной оценке качества: модель выглядит хорошо на проверке и плохо работает в эксплуатации. Основные источники утечки сведены в таблицу 15.

Таблица 15 — Основные источники утечки данных

Источник утечки	Как возникает	Пример
Случайное разбиение	Записи одной атаки попадают и в обучающую, и в тестовую выборки	Модель запоминает адрес нарушителя и «находит» его в тесте
Неверная граница окна	Окно признака захватывает события после момента отсчёта	Для входа в 12:00 доля неудач считается с 11:30 до 12:30, хотя в 12:00 известно только то, что было до него
Решения по всему набору	Признаки отбираются или значения усредняются по всему набору до разбиения	Отбор признаков выполнен с учётом тестовых данных
Повторы и близкие копии	Одна запись или почти одинаковые записи попадают в разные выборки	Повторная доставка записи
Недоступный признак	Признак появляется только после того, как атака уже признана	Результат разбора инцидента как признак
Подбор по тесту	Настройки модели выбираются по тестовой выборке	Многократные запуски до «хорошего» результата

Последний пункт, известный как «подглядывание» в данные, иллюстрирует общий принцип: тестовая выборка моделирует будущее, поэтому её используют один раз, для итоговой оценки, а не для выбора настроек [2].

4.2 Случайное и временное разбиение

Сл. 20

Обычное случайное разбиение предполагает, что объекты независимы. В данных безопасности это не так: события одной атаки идут подряд и похожи друг на друга. При случайном разбиении часть таких объектов окажется в обучающей выборке, часть в тестовой, и модель получит правильный ответ за счёт запоминания, а не обобщения. Кроме того, реальная модель всегда

применяется к будущему, в котором появляются новые виды атак. Разбиение по времени моделирует именно такую ситуацию (рисунок 4).

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Атаки						А	А	А								Б	Б	Б		
Случайное	О	О	Т	О	О	О	Т	О	О	О	Т	О	О	О	О	О	Т	О	О	Т
По времени	О	О	О	О	О	О	О	О	О	О	О	О	О	×	Т	Т	Т	Т	Т	Т

Рисунок 4 — Случайное и временное разбиение (О — обучение, Т — тест, × — зазор). При случайном разбиении обе атаки (А и Б) присутствуют и в обучении, и в тесте; при временном атака А целиком в обучении, а Б только в тесте, как в реальности

Исследование TESSERACT показало, что при оценке с учётом времени качество известных классификаторов вредоносных программ заметно ниже опубликованного: прежние результаты были завышены из-за временного смещения в разбиении [3]. Поэтому в задачах безопасности разбиение по времени считается обязательным.

4.3 Выборки и зазор между ними

Сл. 21

Набор данных делят на три выборки с разными ролями (таблица 16). Выборки следуют друг за другом по времени, между ними выдерживается **зазор** — период, объекты которого не входят ни в одну из соседних выборок. Зазор нужен потому, что признаки по окну и метки, привязанные к инциденту, «растягиваются» во времени: без зазора объект на границе использует события из соседней выборки. Длина зазора не меньше самого длинного окна признаков.

Таблица 16 — Роли выборок

Выборка	Для чего используется	Сколько раз
Обучающая	Подбор параметров модели	Многократно
Проверочная	Выбор настроек модели и порога срабатывания	Многократно
Тестовая	Итоговая оценка качества	Один раз

Пример схемы для наблюдения за 56 дней приведён на рисунке 5. Масштаб условный: зазоры в одни сутки показаны шире, чем в реальной пропорции.



Рисунок 5 — Разбиение по времени с зазорами (× — зазор в одни сутки)

Границы выборок выбирают по датам, а не по числу объектов, и проверяют по нескольким правилам. Каждая выборка должна содержать объекты каждого класса, иначе качество на ней нельзя оценить (если атака произошла один раз, она оказывается только в одной выборке). Доля атак в проверочной и тестовой выборках должна быть сопоставима. Размеры выборок обычно составляют примерно 60, 20 и 20 процентов периода.

4.4 Подготовка данных без утечки

Сл. 22

Операции, в которых решение принимается по значениям данных (отбор признаков, вычисление средних значений, искусственное изменение баланса классов), выполняют после разбиения. Решение принимается по обучающей выборке и затем только применяется к проверочной и тестовой (рисунок 6). Рекомендации по обработке данных в машинном обучении, в том числе в библиотеке scikit-learn, требуют именно такого порядка: решения, принятые по всему набору, дают завышенные оценки [4].

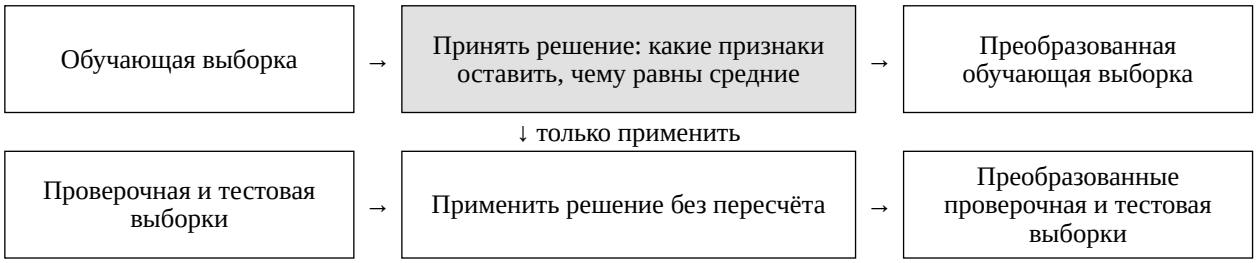


Рисунок 6 — Решения принимаются только по обучающей выборке

Сл. 23

Какие операции допустимо выполнять над всем набором, а какие только над обучающей выборкой, показано в таблице 17.

Таблица 17 — Где выполняются операции подготовки

Операция	Где выполняется	Причина
Проверка схемы, удаление повторов, нормализация формата, маскирование	Весь набор	Не принимают решений по значениям данных
Признаки по прошлому (окно до момента отсчёта)	Весь набор	Не используют будущие события
Отбор признаков, средние значения	Обучающая выборка	Результат зависит от значений данных и меток
Искусственное изменение баланса классов	Обучающая выборка	Искусственные объекты не должны попасть в проверку
Выбор настроек модели и порога	Проверочная выборка	Тест остаётся нетронутым для итоговой оценки
Итоговая оценка	Тестовая выборка, один раз	Моделирует будущее

5 Метки и шум в разметке

5.1 Источники меток

Сл. 24, 25

Метки получают из нескольких источников, и у каждого есть сильные и слабые стороны (таблица 18). Выбор источника определяет, чему научится модель.

Таблица 18 — Источники меток

Источник	Сильная сторона	Слабая сторона
Результаты правил обнаружения	Дёшево, охватывает весь журнал	Модель научится повторять правила; пропущенные правилами атаки получат метку «норма»
Разбор сигналов аналитиками	Высокая точность меток	Размечается только то, что попало в разбор; дорого
Отчёты об инцидентах	Подтверждённые атаки с описанием	Неточное время начала и конца, пропуски
Воспроизведённые атаки (учебный стенд, тест на проникновение)	Известны точные время и сценарий	Атаки могут отличаться от реальных
Готовые наборы данных	Не требуют разметки	Содержат ошибки и отличаются от вашей системы

5.2 Шум в разметке и способы работы с ним

Сл. 26

Шумом в разметке называются ошибки в метках. Для безопасности он особенно характерен: часть атак остаётся необнаруженной и попадает в данные как «норма», а метка инцидента привязывается ко времени регистрации, а не к времени самой атаки (рисунок 7). Даже популярные открытые наборы данных содержат такие ошибки: для набора CICIDS2017 обнаружены ошибки разметки и имитации атак [5].

	1	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**	**11**	**12**
Реальная атака				●	●	●						
Метка (с задержкой)							●	●	●			
Результат				✗	✗	✗	✗	✗	✗			

Рисунок 7 — Сдвиг метки по времени: объекты 4–6 (реальная атака) размечены как норма, объекты 7–9 — как атака, которой на самом деле нет

Сл. 27

Виды шума и способы работы с ним сведены в таблицы 19 и 20.

Таблица 19 — Виды шума в разметке

Вид шума	Причина	Последствие
Пропущенные атаки	Атака не обнаружена, объект получил метку «норма»	Модель считает нормой реальную атаку; качество занижено
Ложные метки	Метка выставлена по ложному сигналу без проверки	Модель учится на несуществующих атаках
Сдвиг во времени	Метка привязана ко времени регистрации инцидента	Признаки и метка относятся к разным периодам

Таблица 20 — Способы работы с шумом в разметке

Способ	Идея	Ограничение
Выборочная проверка аналитиком	Спорные объекты и случайная выборка перепроверяются вручную	Дорого, охватывает малую часть
Зазор вокруг инцидента	Объекты рядом с границей инцидента исключаются из обучения	Теряется часть данных
Мягкие метки	Вместо «0» и «1» используется вероятность атаки	Нужно обоснование вероятностей
Уверенное обучение	Находятся объекты, метка которых противоречит предсказаниям модели, полученным на отложенных частях данных; их перепроверяют [6]	Находит лишь подозрения, решение за аналитиком

6 Дрейф данных

6.1 Виды дрейфа

Сл. 28, 29

Дрейфом данных называется изменение статистических свойств данных или связи между признаками и меткой с течением времени [7]. В безопасности причины дрейфа очевидны: меняются приложения, пользователи и техники нарушителей. Модель, обученная на прошлом, со временем начинает ошибаться. Виды дрейфа приведены в таблице 21.

Таблица 21 — Виды дрейфа данных

Вид	Как проявляется	Пример
Резкий	Свойства данных меняются скачком	Обновление приложения изменило формат и частоту событий
Постепенный	Свойства меняются медленно	Рост числа пользователей, переход в облачную инфраструктуру
Повторяющийся	Изменения циклически повторяются	Рабочие и выходные дни, конец месяца

6.2 Обнаружение дрейфа

Сл. 30

Дрейф обнаруживают сравнением распределений признаков в обучающих данных и в данных, поступающих в эксплуатации. Распространённая мера — **индекс стабильности популяции** (PSI). Диапазон значений признака делят на интервалы и для каждого сравнивают долю объектов в обучающих данных q_i и в текущих p_i:

$$\mathrm{PSI} = \sum_i (p_i - q_i) \ln\left(\frac{p_i}{q_i}\right). \tag{4}$$

Рассмотрим признак «число попыток входа за окно» с тремя интервалами (таблица 22). Доли в текущих данных сместились: PSI составил 0,177.

Таблица 22 — Пример расчёта PSI для одного признака

Интервал	**Обучение** q_i	**Сейчас** p_i	$p_i - q_i$	**Вклад в PSI**
1–2 попытки	0,70	0,50	−0,20	0,067
3–10 попыток	0,20	0,30	+0,10	0,041
более 10 попыток	0,10	0,20	+0,10	0,069
Итого	1,00	1,00	—	0,177

Сл. 31

Значение PSI интерпретируют по принятым на практике порогам (таблица 23). Это соглашения, а не статистические критерии, поэтому ими пользуются осторожно, учитывая выбор интервалов [8].

Таблица 23 — Принятые пороги PSI

PSI	Интерпретация
менее 0,1	Распределение стабильно
от 0,1 до 0,25	Умеренное изменение: стоит разобраться в причинах
более 0,25	Существенное изменение: качество модели под угрозой

Для обнаружения изменения во времени в потоке данных применяют также тест Пейджа–Хинкли, накапливающий отклонения наблюдаемой величины от её среднего и сигнализирующий при превышении порога. Если метки доступны, дрейф можно обнаружить и по падению Precision (точности) и Recall (полноты обнаружения) на свежих размеченных данных; это самый прямой, но и самый запаздывающий признак, поскольку метки поступают с задержкой.

6.3 Реакция на дрейф

Сл. 32

Меры, применяемые при обнаружении дрейфа, приведены в таблице 24.

Таблица 24 — Реакция на дрейф данных

Мера	Содержание	Цена
Плановое переобучение	Модель регулярно обучается заново на свежих данных (еженедельно, ежемесячно)	Затраты на обучение и проверку
Постепенное обучение	Модель дообучается по мере поступления новых данных	Накопление ошибок, риск «отравления» данных
Пересмотр порогов и правил	Настройки подстраиваются под новое поведение	Требует участия специалиста
Ручной разбор	При существенном дрейфе модель проверяется аналитиком	Задержка реакции

ЗАКЛЮЧЕНИЕ

Сл. 33

Главное по каждой главе лекции сведено в таблицу 25.

Таблица 25 — Основные положения лекции

Глава	Главное
1. Набор данных для аналитической модели	Набор строится из журнала: объекты, признаки, метки; конвейер с проверкой на каждом этапе
2. Качество данных	Данные проверяют до обучения: схема, повторы, непрерывность, единообразие
3. Построение признаков	Признаки считаются по событиям, известным в момент решения; набор признаков различает разные атаки
4. Разбиение данных по времени	Разбиение по времени с зазором; решения принимаются только по обучающей выборке
5. Метки и шум в разметке	Метки неточны: разметку проверяют и не доверяют ей безоговорочно
6. Дрейф данных	Данные меняются: дрейф измеряют и планируют реакцию

На практическом занятии 4 из журнала веб-приложения строится набор данных: проверка и нормализация записей, построение признаков, присвоение меток, разбиение по времени и проверка отсутствия утечки.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Sommer R., Paxson V. Outside the Closed World: On Using Machine Learning for Network Intrusion Detection // Proceedings of the IEEE Symposium on Security and Privacy. 2010. Сс. 305–316.
2. Arp D. и др. Dos and Don'ts of Machine Learning in Computer Security // Proceedings of the 31st USENIX Security Symposium. 2022. Сс. 3971–3988.
3. Pendlebury F. и др. TESSERACT: Eliminating Experimental Bias in Malware Classification across Space and Time // Proceedings of the 28th USENIX Security Symposium. 2019. Сс. 729–746.
4. scikit-learn developers. Common pitfalls and recommended practices. scikit-learn User Guide [Электронный ресурс]. 2025. URL: https://scikit-learn.org/stable/common_pitfalls.html.
5. Engelen G., Rimmer V., Joosen W. Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study // Proceedings of the IEEE Security and Privacy Workshops. 2021.
6. Northcutt C., Jiang L., Chuang I. Confident Learning: Estimating Uncertainty in Dataset Labels // Journal of Artificial Intelligence Research. 2021. Т. 70. Сс. 1373–1411.
7. Gama J. и др. A Survey on Concept Drift Adaptation // ACM Computing Surveys. 2014. Т. 46, № 4. Сс. 1–37.
8. A critical review of existing and new population stability testing procedures in credit risk scoring [Электронный ресурс]. 2023. URL: https://arxiv.org/abs/2303.01227.

ПРИЛОЖЕНИЕ А

Вопросы для самопроверки

Каждый вопрос сопровождается кратким ответом, составленным по материалу лекции.

1. Чем данные информационной безопасности отличаются от данных в типовых задачах машинного обучения?

Ответ. Пять основных особенностей: крайний дисбаланс классов (атаки составляют доли процента), зависимость событий от времени, дрейф (поведение пользователей и нарушителей меняется), шум в разметке (часть атак не обнаружена, метки сдвинуты по времени) и противодействие нарушителя, который подстраивается под средства защиты.

2. Что такое объект, признак и метка? Приведите пример объекта для обнаружения подбора пароля.

Ответ. Объект — строка набора данных, то есть единица, о которой модель принимает решение; признак — число, описывающее объект; метка — известный ответ (атака или нормальная работа). Для подбора пароля объектом может быть адрес источника за пятиминутное окно, признаками — число попыток, доля неудач и число различных учётных записей, меткой — «атака» или «норма».

3. Что такое момент отсчёта и почему при вычислении признаков нельзя использовать события после него?

Ответ. Момент отсчёта — время, на которое строится описание объекта и в которое модель будет принимать решение. В реальной работе события после этого момента ещё не произошли, поэтому их использование даёт модели сведения, которых у неё не будет в эксплуатации. Это утечка данных из будущего, она завышает качество на проверке.

4. Какие проверки качества данных выполняют до построения признаков?

Ответ. Проверку схемы записей (обязательные поля, типы, допустимые значения), поиск повторов, контроль непрерывности потока (нет ли часов без записей), единообразие форматов (время, адреса, регистр имён) и

порядок времени (отметки не уходят в будущее). Нарушение любой проверки останавливает конвейер.

5. Почему случайное разбиение приводит к утечке при обнаружении атак?

Ответ. События одной атаки идут подряд и похожи друг на друга. При случайном разбиении часть таких объектов попадает в обучающую выборку, часть в тестовую, и модель отвечает правильно за счёт запоминания (например, адреса нарушителя), а не обобщения. Кроме того, в реальности модель применяется к будущему с новыми видами атак, чего случайное разбиение не моделирует.

6. Зачем нужен зазор между выборками и какой он длины?

Ответ. Признаки по окну и метки, привязанные к инциденту, растягиваются во времени. Без зазора объект на границе использовал бы события соседней выборки. Длина зазора не меньше самого длинного окна признаков; например, при окне в сутки зазор в одни сутки.

7. Какие операции подготовки допустимо выполнять над всем набором, а какие только по обучающей выборке? Почему?

Ответ. Над всем набором допустимо то, что не принимает решений по значениям данных: проверка схемы, удаление повторов, нормализация формата, маскирование и признаки по прошлому. Отбор признаков, вычисление средних значений и искусственное изменение баланса классов принимают решения по значениям данных, поэтому их выполняют только по обучающей выборке и затем применяют к остальным, иначе информация из проверки попадает в обучение.

8. Приведите пример признака, недоступного в момент применения модели.

Ответ. Результат разбора инцидента аналитиком: он появляется только после того, как атака уже признана. Модель, обученная с таким признаком, фактически получает метку в виде признака и показывает завышенное качество, но в эксплуатации этого признака нет.

9. Какие агрегатные признаки различают подбор пароля к одной учётной записи, распыление паролей и работу офиса за общим адресом?

Ответ. Число попыток велико и у атак, и у офиса, поэтому само по себе не различает. Доля неудач высока у подбора и распыления и низка у офиса. Число различных учётных записей велико у распыления и офиса, но мало у подбора; вместе с долей неудач оно отделяет распыление от офиса. Поэтому признаки подбирают набором.

10. Что такое шум в разметке и чем опасны необнаруженные атаки?

Ответ. Шум в разметке — ошибки в метках: пропущенные атаки, ложные метки и сдвиг метки по времени. Необнаруженная атака попадает в данные как «норма», и модель учится считать нормой реальную атаку, а оценка качества занижается, так как найденная атака засчитывается как ложное срабатывание.

11. Рассчитайте PSI для признака с долями в обучающих данных 0,80; 0,15; 0,05 и в текущих 0,60; 0,25; 0,15. Как интерпретировать результат?

Ответ. Вклады интервалов: $(0{,}60 - 0{,}80) \cdot \ln(0{,}60/0{,}80) = 0{,}058$; $(0{,}25 - 0{,}15) \cdot \ln(0{,}25/0{,}15) = 0{,}051$; $(0{,}15 - 0{,}05) \cdot \ln(0{,}15/0{,}05) = 0{,}110$. Итого $\mathrm{PSI} \approx 0{,}22$, то есть умеренное изменение (от 0,1 до 0,25), близкое к существенному: следует разобраться в причинах и подготовиться к переобучению.

12. Почему тестовую выборку используют один раз?

Ответ. Тестовая выборка моделирует будущее, поэтому служит только для итоговой оценки. Если по ней выбирать настройки модели или многократно повторять запуски, настройки подстраиваются под неё, и оценка перестаёт показывать качество на новых данных. Настройки выбирают по проверочной выборке.