Лекция 4

Подготовка данных для аналитических моделей

Качество данных · признаки · разбиение по времени · дрейф

План лекции

1. Набор данных
2. Качество данных
3. Построение признаков
4. Разбиение по времени
5. Метки и шум в разметке
6. Дрейф данных

1

Набор данных

из чего учится модель

Основные понятия набора данных

Понятие	Что означает	Пример
Набор данных	Таблица, из которой модель получает примеры для обучения и проверки	Все объекты за 56 дней наблюдения
Объект	Одна строка набора: то, о чём модель принимает решение	Адрес источника за 5-минутное окно
Признак	Числовая характеристика объекта, вычисленная по журналу	Число попыток входа в окне
Метка	Известный ответ для объекта: атака или нормальная работа	«атака: подбор пароля»
Выборка	Часть набора данных с определённой ролью	Обучающая, проверочная, тестовая

> В работе используется только то, что будет известно и в момент реального применения

От записей журнала к объекту

Время	Адрес	Учётная запись	Итог
09:00:04	203.0.113.7	anna	неудача
09:00:09	203.0.113.7	anna	неудача
09:00:15	203.0.113.7	anna	неудача
09:00:21	203.0.113.7	anna	неудача
09:02:40	198.51.100.5	boris	успех

→

Объект
адрес 203.0.113.7, окно 09:00–09:05

Число попыток	**4**
Доля неудач	**1,0**
Разных записей	**1**
Метка	**атака**

Объект — строка набора данных: числа-признаки и метка вместо записей журнала

Особенности данных безопасности

Дисбаланс классов

атаки — доли процента объектов

Зависимость от времени

события одной атаки идут подряд

Дрейф

поведение пользователей и нарушителей меняется

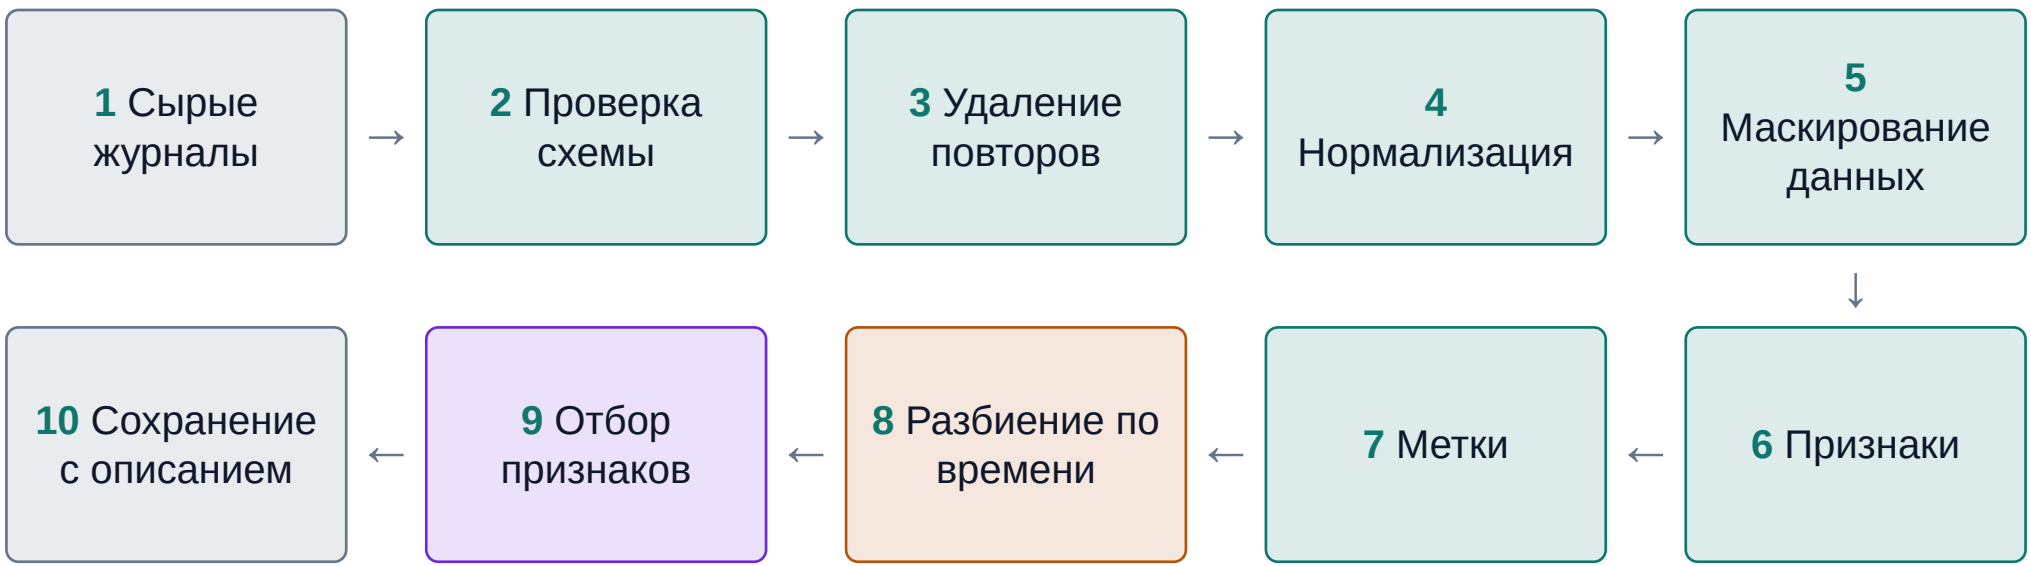
Шум в разметке

часть атак не обнаружена и помечена нормой

Противодействие

нарушитель подстраивается под защиту

Конвейер подготовки данных



2–7: без решений по данным — весь журнал

8: разбиение

9: решения — только по обучающей

2

Качество данных

проверять до обучения

Типичные проблемы

Пропуски

смещение оценок

Повторы

завышенное качество

Разрывы потока

тишина принимается за норму

Разные форматы

ошибки разбора и порядка событий

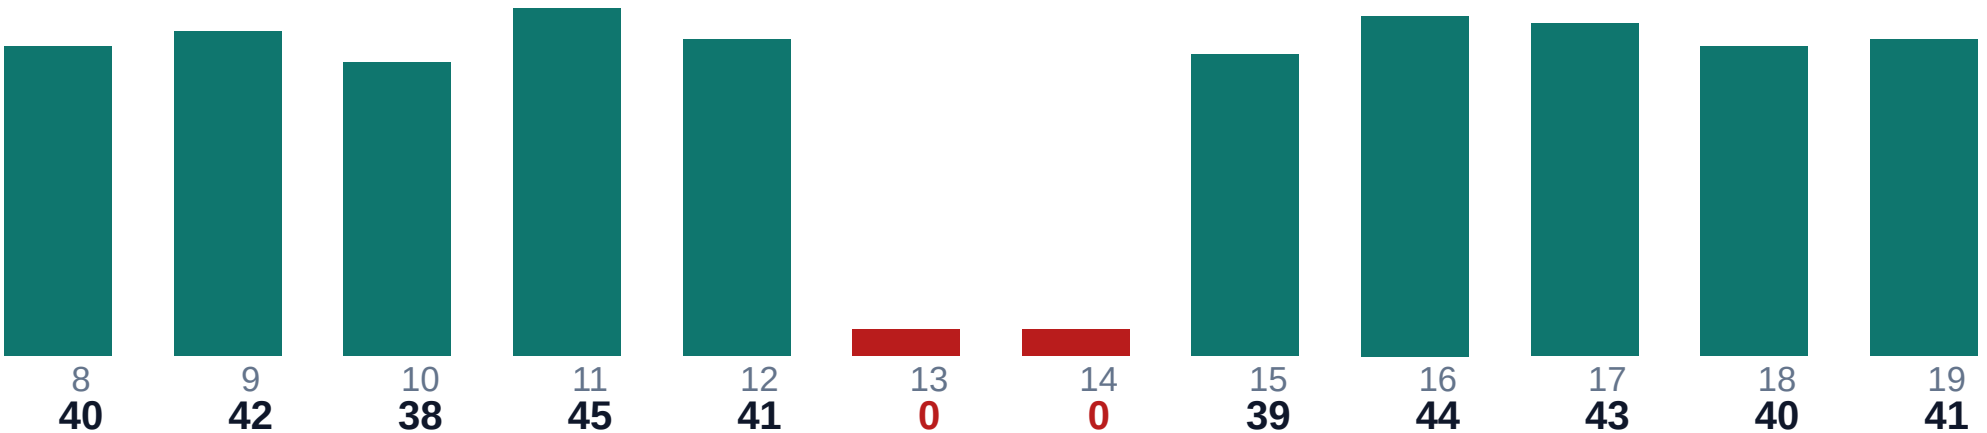
Неверные метки

модель учится на ошибках

Персональные данные

риск утечки набора

Разрыв потока выглядит как тишина



число записей по часам

13–14 ч: источник молчал, но атака шла — в данных «норма»

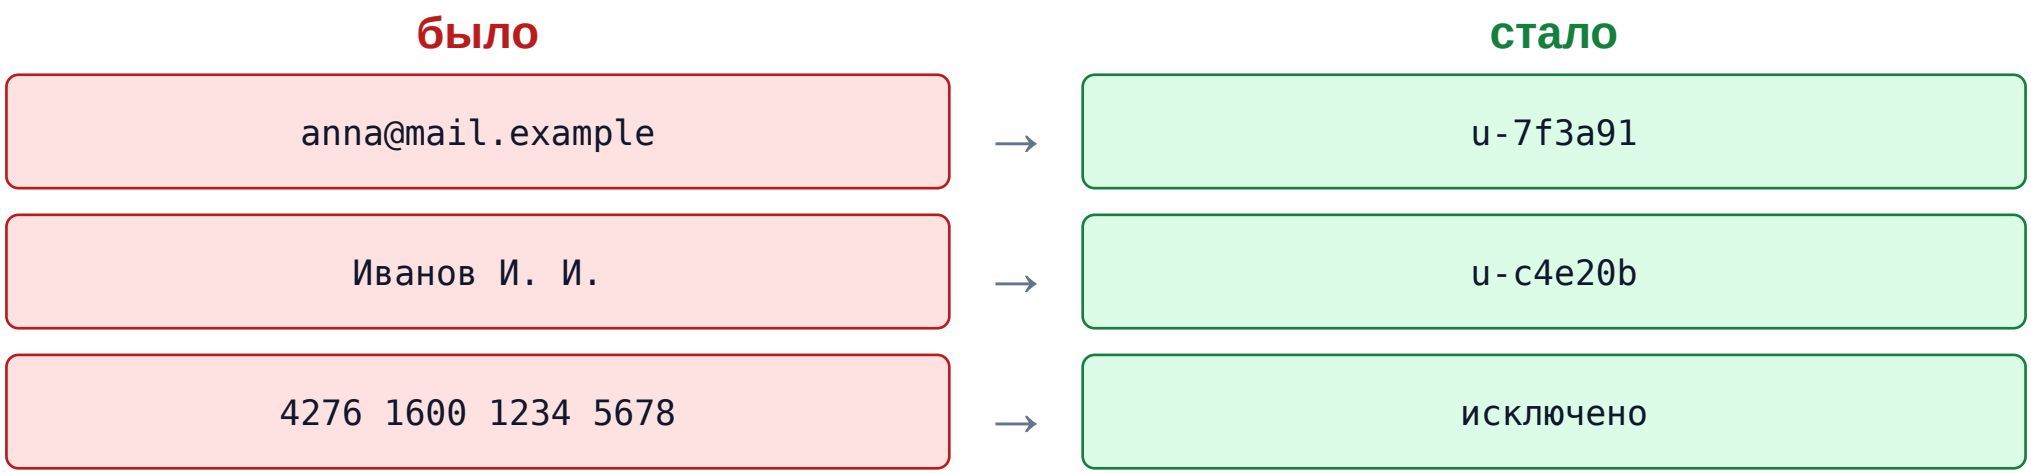
Нулевые и аномально малые часы помечают и проверяют

Проверки качества

Схема записи	обязательные поля, типы, допустимые значения
Повторы	по номеру записи или сочетанию времени, источника, типа
Непрерывность	число записей по часам; нули помечаются
Единообразие	время в UTC, одна форма адреса, один регистр
Порядок времени	отметки не в будущем и не вне периода

> Нарушение любой проверки останавливает конвейер

Маскирование до построения признаков



Псевдоним постоянен: агрегаты по пользователю считаются, личность без ключа не устанавливается

3

Построение признаков

что видит модель

Три вида признаков

Событийные

характеристика одной записи

час суток, причина неудачи, клиентское приложение

Агрегатные

статистика сущности за окно

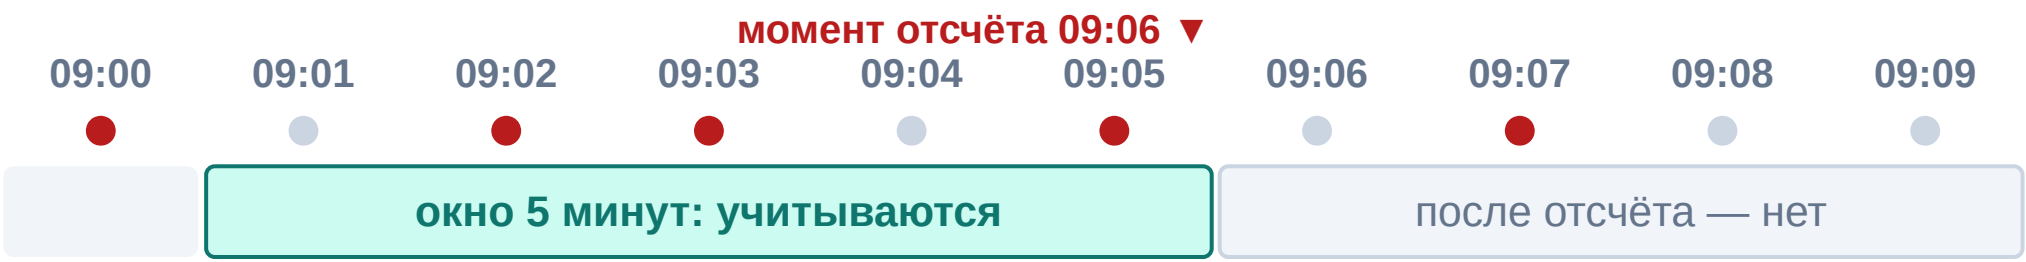
число попыток, доля неудач, число разных учётных записей

Статистические

отклонение от обычного уровня

число попыток к среднему за 7 дней

Окно и момент отсчёта



Окно заканчивается в момент отсчёта: будущих событий в реальной работе ещё нет

Четыре объекта — четыре набора чисел

Объект (окно 5 минут)	Попыток	Доля неудач	Разных записей	Метка
A · пользователь ошибся в пароле	2	0,50	1	норма
B · подбор пароля к одной записи	8	1,00	1	атака
C · распыление паролей	9	1,00	9	атака
D · офис за общим адресом	40	0,08	25	норма

Ни один признак не разделяет все случаи: C и D различает доля неудач, B и C — число разных записей

Отбор и описание признаков

Способы отбора

- Убрать сильно связанные признаки (|r| > 0,95)
- Убрать почти постоянные признаки
- Взаимная информация с меткой
- Важность перестановкой

Описание признака

Имя: `failure_share_5m`
Что: доля неудач среди попыток за 5 минут
Границы: число от 0 до 1
Источник: поле `outcome`, тип `auth.login`
Окно: 5 минут до момента отсчёта
Особый случай: при 0 попыток — значение 0

Решение, какие признаки оставить, принимается только по обучающей выборке

4

Разбиение по времени

защита от утечки данных

Утечка данных из будущего

Случайное разбиение

одна атака — и в обучении, и в тесте

Неверная граница окна

окно захватывает события после момента отсчёта

Параметры по набору

среднее считается до разбиения

Повторы и копии

одна запись попала в разные выборки

Недоступный признак

результат разбора инцидента как признак

Подбор по тесту

настройки выбираются по тестовой выборке

Итог утечки: хорошая оценка на проверке и плохая работа в эксплуатации

Случайное и временное разбиение

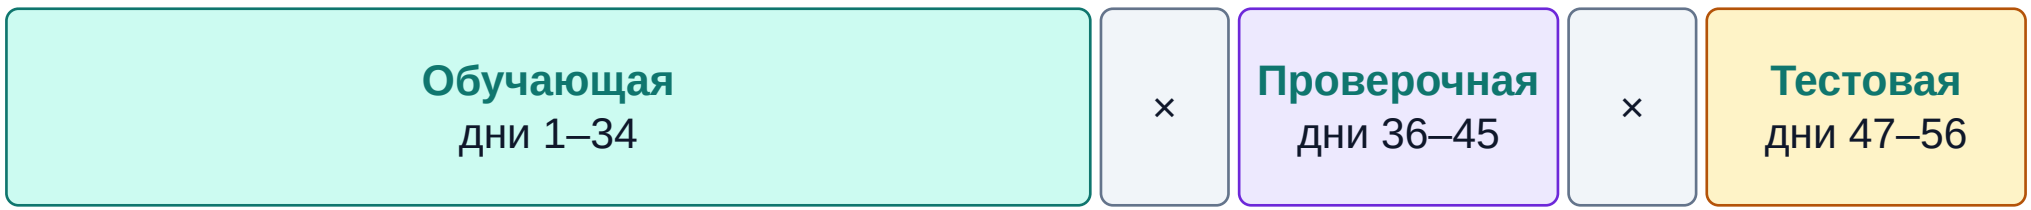
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Атаки						А	А	А								Б	Б	Б		
Случайное	О	О	Т	О	О	О	Т	О	О	О	Т	О	О	О	О	О	Т	О	О	Т
По времени	О	О	О	О	О	О	О	О	О	О	О	О	О	×	Т	Т	Т	Т	Т	Т

О — обучение Т — тест × — зазор

Случайное: обе атаки (А и Б) есть и в обучении, и в тесте — модель их «помнит», оценка завышена

По времени: А только в обучении, Б только в тесте — модель видит новую атаку, как в реальной работе

Выборки и зазор



Обучающая

подбор параметров модели

Проверочная

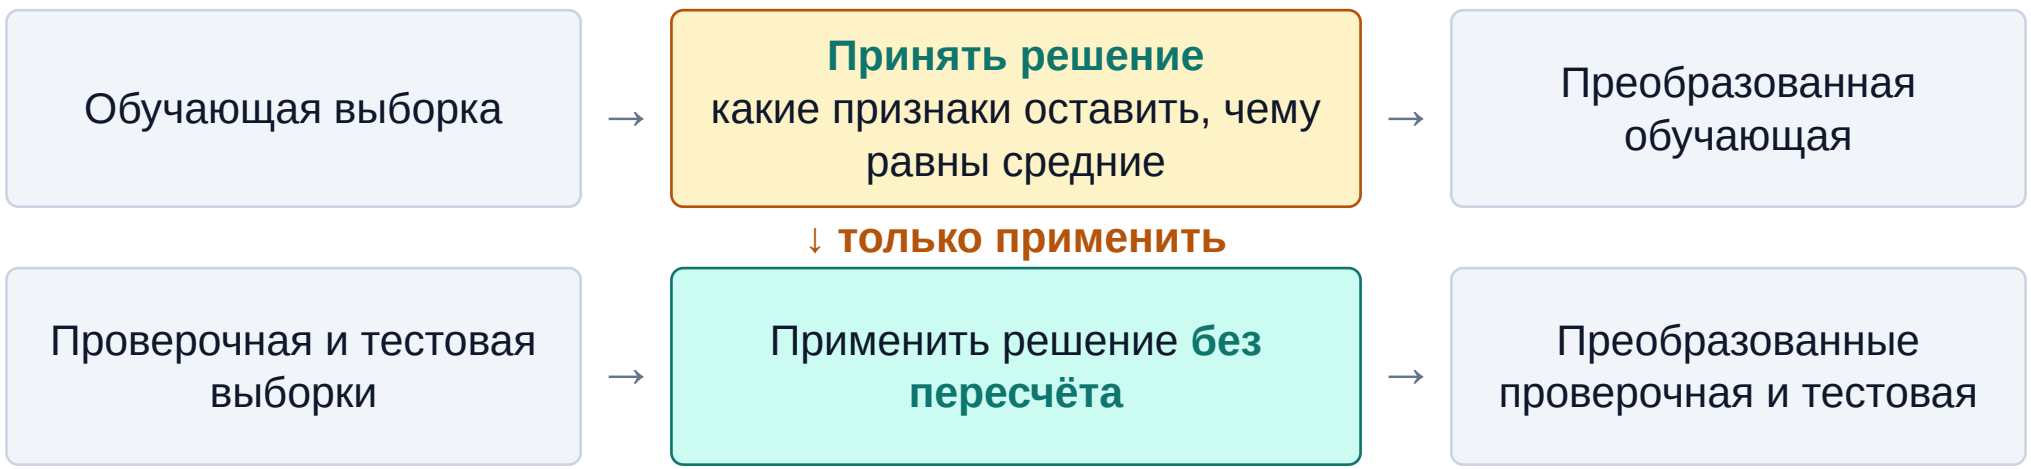
выбор настроек и порога

Тестовая

итоговая оценка — один раз

Зазор не короче самого длинного окна признаков

Подготовка без утечки



Решения принимаются только по обучающей выборке

Что и где вычисляется

Весь набор

проверка схемы
удаление повторов
нормализация
маскирование
признаки по прошлому

Только обучающая

отбор признаков
средние значения
изменение баланса классов

Проверка и тест

проверочная: настройки и порог
тестовая: итоговая оценка, один раз

5

Метки и шум в разметке

откуда берутся ответы

Откуда берутся метки

Результаты правил	⚠ модель научится повторять правила
Разбор аналитиками	⚠ размечено только то, что попало в разбор
Отчёты об инцидентах	⚠ неточное время начала и конца
Воспроизведённые атаки	⚠ могут отличаться от реальных
Готовые наборы данных	⚠ содержат ошибки, чужая система

Сдвиг метки по времени

	1	2	3	4	5	6	7	8	9	10	11	12
Реальная атака				●	●	●						
Метка в журнале							●	●	●			
Результат				✗	✗	✗	✗	✗	✗			

Объекты 4–6: реальная атака помечена нормой

Объекты 7–9: метка «атака», а атаки уже нет

Работа с шумом в разметке

Выборочная проверка

спорные объекты и случайная выборка перепроверяет аналитик

Зазор вокруг инцидента

объекты у границы инцидента исключаются из обучения

Мягкие метки

вместо «0» и «1» — вероятность атаки

Уверенное обучение

метки, противоречащие предсказаниям модели, перепроверяются

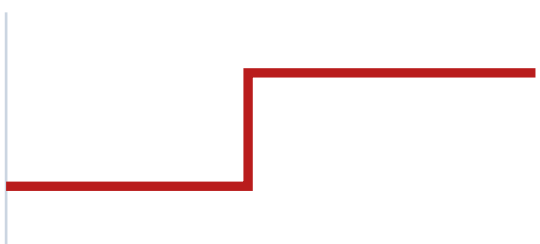
6

Дрейф данных

данные меняются

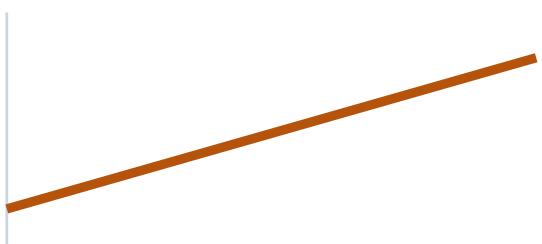
Виды дрейфа

Резкий



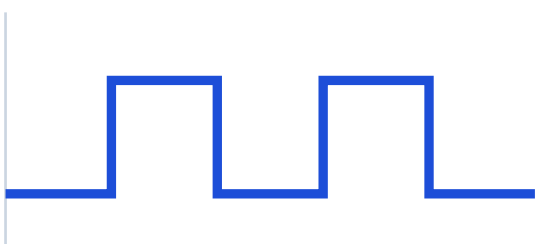
обновление приложения

Постепенный



рост числа пользователей

Повторяющийся



рабочие и выходные дни

PSI: сравнение распределений

$$\mathrm{PSI} = \sum_i (p_i - q_i) \ln\left(\frac{p_i}{q_i}\right)$$

q — доля объектов в обучающих данных, p — в текущих

Число попыток	q	p	p − q	Вклад
1–2	0,70	0,50	−0,20	0,067
3–10	0,20	0,30	+0,10	0,041
более 10	0,10	0,20	+0,10	0,069
Итого	1,00	1,00	—	**0,177**

Как читать PSI



Пороги — соглашения, а не статистические критерии: выбор интервалов влияет на результат

Ещё: тест Пейджа–Хинкли для потока данных; падение Precision и Recall на свежих размеченных данных — самый прямой, но запаздывающий признак

Реакция на дрейф

Плановое переобучение

регулярно на свежих данных

цена: затраты на обучение и проверку

Постепенное обучение

дообучение по мере поступления данных

цена: накопление ошибок, «отравление»

Пересмотр порогов и правил

подстройка под новое поведение

цена: нужен специалист

Ручной разбор

проверка модели аналитиком

цена: задержка реакции

Главное

1 Набор данных	Объекты, признаки, метки
2 Качество данных	Проверяем данные до обучения
3 Признаки	Считаются по известным событиям
4 Разбиение по времени	Со временем и зазором, без утечки
5 Метки и шум	Разметку проверяем, ей не верим слепо
6 Дрейф	Данные меняются — измеряем дрейф

Лекция 4

Подготовка данных для аналитических моделей

Качество данных · признаки · разбиение по времени · дрейф