Повышение квалификации специалистов по информационной безопасности

**КОНСПЕКТ ЛЕКЦИИ 5**

по курсу
«Методы и принципы проектирования современных защищённых систем. Применение механизмов искусственного интеллекта для анализа данных при построении систем информационной безопасности»

# МОДЕЛИ КЛАССИФИКАЦИИ ДЛЯ ОБНАРУЖЕНИЯ ИНЦИДЕНТОВ

Дисбаланс классов, метрики, выбор порога, интерпретация

(2 академических часа)

2026

**СОДЕРЖАНИЕ**

Введение . . . . . 4

1 Место модели в обнаружении . . . . . 5

1.1 Когда оправдана модель . . . . . 5

1.2 Учебный набор данных . . . . . 5

2 Дисбаланс классов . . . . . 7

2.1 Масштаб проблемы . . . . . 7

2.2 Методы работы с дисбалансом . . . . . 8

2.3 Рекомендуемый порядок . . . . . 8

3 Модели классификации . . . . . 9

3.1 Логистическая регрессия . . . . . 9

3.2 Ансамбли деревьев . . . . . 9

3.3 Настройка и выбор модели . . . . . 10

4 Метрики и выбор порога . . . . . 11

4.1 Исходы и метрики . . . . . 11

4.2 Кривая «точность — полнота» и ROC-кривая . . . . . 12

4.3 Выбор порога . . . . . 13

4.4 Правила передачи на анализ . . . . . 15

5 Интерпретация модели . . . . . 16

5.1 Зачем объяснять решения . . . . . 16

5.2 Веса признаков линейной модели . . . . . 16

5.3 Важность признаков перестановкой . . . . . 17

5.4 Значения SHAP . . . . . 18

6 Эксплуатация и паспорт модели . . . . . 21

6.1 Конвейер модели . . . . . 21

6.2 Требования к эксплуатации . . . . . 21

6.3 Паспорт модели . . . . . 22

Заключение ..... 24

Список использованных источников ..... 25

Приложение А Вопросы для самопроверки ..... 27

# ВВЕДЕНИЕ

Сл. 1, 2

В лекции рассматривается применение моделей машинного обучения для обнаружения инцидентов информационной безопасности: отличие модели от правила обнаружения, трудности, связанные с малой долей атак, сравнение моделей, выбор порога срабатывания и объяснение решений модели. Изложение опирается на один учебный набор данных; все числовые значения получены расчётом на этом наборе.

Сл. 3

**Классификацией** называется задача отнесения объекта к одному из заранее заданных классов. При обнаружении атак классов два: «норма» и «атака», а объектом служит строка набора данных, например «адрес источника за пять минут» с числовыми признаками активности. Модель не формирует итоговое решение: она вычисляет для объекта числовую величину — **оценку**, значение которой тем выше, чем в большей степени объект соответствует признакам атаки. Решение принимается сравнением оценки с **порогом**: объекты с оценкой не ниже порога формируют сигнал, подлежащий анализу. Эту цепочку показывает рисунок 1.




Рисунок 1 — От объекта к сигналу

Качество системы определяется двумя независимыми решениями: выбором модели, вычисляющей оценку, и выбором порога. Оба решения принимаются по данным и проверяются на данных, не использованных при обучении. Структура лекции показана в таблице 1.

Таблица 1 — Последовательность изложения

| Глава | Вопрос | Результат |
|---|---|---|
| 1 | Когда нужна модель, а не правило? | Место модели в обнаружении, учебный набор данных |
| 2 | Что делать, если атак почти нет? | Методы работы с дисбалансом классов |
| 3 | Какую модель выбрать? | Сравнение моделей и настройка |
| 4 | Как оценить модель и выбрать порог? | Метрики, порог, правила передачи на анализ |
| 5 | Почему модель так решила? | Интерпретация |
| 6 | Как передать модель в эксплуатацию? | Требования и паспорт модели |

## 1 Место модели в обнаружении

### 1.1 Когда оправдана модель

Сл. 5

Применение модели целесообразно не во всех задачах. В исследованиях отмечается, что использование методов машинного обучения в задачах информационной безопасности нередко оказывается неэффективным вследствие несоответствия постановки задачи свойствам метода [1,2]. Простое условие, например «пять неудачных входов за десять минут», целесообразнее описывать правилом обнаружения. Модель необходима, когда отдельный признак не позволяет принять решение, а информативно только сочетание признаков. Основные критерии выбора собраны в таблице 2.

Таблица 2 — Выбор между правилом и моделью

| Условие задачи | Правило | Модель |
|---|---|---|
| Атаку описывает одно пороговое условие | Подходит | Избыточна |
| Значимо сочетание многих слабых признаков | Трудно записать | Подходит |
| Нет размеченных примеров атак | Подходит | Не обучить |
| Требуется обосновать каждое решение перед аналитиком и аудитором | Подходит | Нужна интерпретируемая модель |
| Нет сопровождения: мониторинга и переобучения | Подходит | Качество будет деградировать |

Сл. 6

Поэтому модель дополняет правила обнаружения, а не заменяет их. Систему строят в несколько эшелонов (рисунок 2): правила обнаруживают известные атаки, модель оценивает объекты, не выявленные правилами, а аналитик анализирует итоговые сигналы.

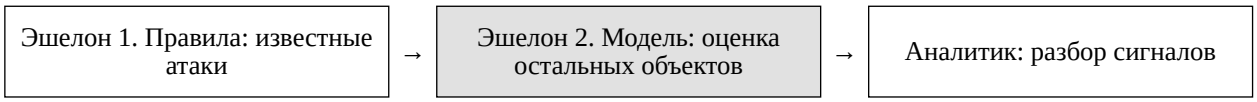



Рисунок 2 — Правила, модель и аналитик

### 1.2 Учебный набор данных

Сл. 7

Все числа лекции получены на одном учебном наборе данных (таблица 3). Объект набора — адрес источника за пятиминутное окно, признаки вычислены по событиям входа в веб-приложение внутри окна, метка «атака» присвоена по отчётам об известных учебных атаках двух видов: подбор пароля

(в журнале виден как серия неудач с последующим успешным входом) и распыление паролей (один пароль, много учётных записей). Данные разбиты по времени: обучение — первые 34 суток, проверка — сутки 36–45, тест — сутки 47–56; сутки 35 и 46 исключены как зазоры.

Таблица 3 — Учебный набор данных

| **Выборка** | **Объектов** | **Атак** | **Доля атак** |
|---|---|---|---|
| Обучающая (дни 1–34) | 4 116 | 15 | 0,36 % |
| Проверочная (дни 36–45) | 1 215 | 6 | 0,49 % |
| Тестовая (дни 47–56) | 1 217 | 6 | 0,49 % |

Признаков четыре: число попыток входа в окне, доля неудачных попыток, число различных учётных записей и индикатор ночного времени. Число атак во всех выборках мало: в проверочной и в тестовой выборках их по шесть. Это обстоятельство существенно для выводов и учитывается далее по тексту.

## 2 Дисбаланс классов

### 2.1 Масштаб проблемы

Сл. 9

**Дисбалансом классов** называется существенное различие числа объектов разных классов в наборе данных. При обнаружении атак редким является класс «атака»: нормальные объекты составляют подавляющее большинство. В учебном наборе атаки составляют около 0,4 % объектов, а в тестовой выборке — 6 из 1 217 (0,49 %).

Наиболее заметное следствие дисбаланса — потеря информативности простейшей метрики Accuracy (доли верных ответов):

$$\mathrm{Accuracy} = \frac{\mathrm{TP} + \mathrm{TN}}{N}, \tag{1}$$

где $N$ — число объектов. Рассмотрим тривиальный классификатор, который для любого объекта выдаёт ответ «норма». Для него $\mathrm{TP} = 0$ и $\mathrm{FP} = 0$, поэтому его Accuracy равна доле нормальных объектов: на тестовой выборке 1 211 / 1 217 = 0,995. С уменьшением доли атак эта величина стремится к единице и не отражает способности обнаруживать атаки. Сравнение такого классификатора с логистической регрессией (порог 0,5) приведено в таблице 4.

Таблица 4 — Тривиальный классификатор и логистическая регрессия при дисбалансе классов

| **Показатель (тестовая выборка)** | **Всегда «норма»** | **Логистическая регрессия** |
|---|---|---|
| Найдено атак | 0 из 6 | 4 из 6 |
| Ложных тревог (FP) | 0 | 14 |
| Accuracy | **0,995** | 0,987 |
| Precision | не определена (сигналов нет) | **0,222** |
| Recall | 0,000 | **0,667** |
| F1 | 0,000 | **0,333** |
| Сбалансированная Accuracy (среднее полноты по двум классам) | 0,500 | **0,828** |

Тривиальный классификатор допускает шесть ошибок, и все они — пропуски атак. Логистическая регрессия допускает 16 ошибок (14 ложных тревог и 2 пропуска), но находит четыре атаки из шести. По Accuracy первый классификатор превосходит второй, по остальным показателям — уступает:

Accuracy придаёт одинаковый вес всем ошибкам, тогда как пропуск атаки и ложная тревога имеют разную стоимость.

Дисбаланс влияет и на обучение: при минимизации суммарной ошибки выгодно игнорировать редкий класс. Поэтому качество оценивают метриками редкого класса (глава 4), а в обучение вводят специальные меры (подраздел 2.2).

### 2.2 Методы работы с дисбалансом

Сл. 10

Методы делятся по тому, где вмешиваются в процесс (таблица 5).

Таблица 5 — Методы работы с дисбалансом

| Уровень | Метод | Особенности |
|---|---|---|
| Данные | Уменьшение числа нормальных объектов | Сохраняет реальные данные, но теряет информацию |
| Данные | Увеличение числа атак: копирование или создание синтетических примеров (например, метод SMOTE) [3] | Синтетические примеры строятся по существующим атакам и не создают новых видов атак |
| Алгоритм | Веса классов: ошибке на объекте редкого класса присваивается больший вес | Не изменяет данные; поддерживается большинством моделей |
| Решение | Выбор порога вместо стандартного 0,5 | Не требует переобучения; настраивается по проверочной выборке |

Число примеров изменяют **только в обучающей выборке**: если синтетические атаки создаются до разбиения, копии одной атаки попадают и в обучающую, и в проверочную выборки, и оценка завышается [2,4].

### 2.3 Рекомендуемый порядок

Сл. 11

Меры применяют от менее инвазивных к более сложным (рисунок 3): веса классов, порог по проверочной выборке и, если результата недостаточно, изменение числа примеров в обучении.

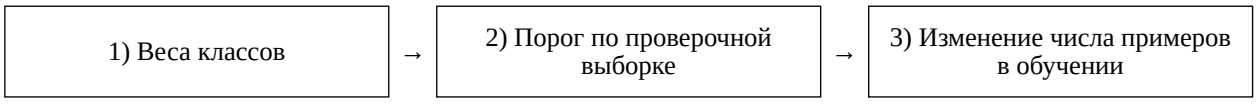



Рисунок 3 — Порядок работы с дисбалансом

Следствие: при весах классов выход модели — не вероятность атаки, а оценка для упорядочения объектов; границу между сигналом и нормой задаёт порог, выбранный по данным.

# 3 Модели классификации

## 3.1 Логистическая регрессия

Сл. 13

**Логистическая регрессия** вычисляет взвешенную сумму признаков и преобразует её в число от 0 до 1. Вес каждого признака характеризует направление и силу его влияния, поэтому модель обучается быстро и допускает простое объяснение. Её ограничение — линейность: сложные сочетания признаков ею не учитываются. Эту модель принимают в качестве базовой: более сложная модель должна продемонстрировать превосходство над ней.

## 3.2 Ансамбли деревьев

Сл. 13, 14

**Решающее дерево** последовательно делит объекты по значениям признаков; **ансамбль** объединяет много деревьев. В случайном лесу деревья строятся независимо на случайных подвыборках и усредняются [5]; в градиентном бустинге каждое следующее дерево исправляет ошибки предыдущих [6]. Такие модели не требуют масштабирования признаков и улавливают нелинейные сочетания. Для табличных данных среднего размера (порядка десяти тысяч объектов) ансамбли деревьев в сравнительных исследованиях показывают результаты не ниже, чем нейронные сети [7], поэтому нейронные сети для таких задач в качестве первого выбора не рассматриваются. Сравнение моделей приведено в таблице 6.

Таблица 6 — Сравнение моделей классификации

| Модель | Обучение | Объяснимость | Когда применять |
|---|---|---|---|
| Логистическая регрессия | Очень быстрое | Высокая: веса признаков | Базовая модель, нужна простота и объяснимость |
| Случайный лес | Быстрое | Средняя: важность признаков | Устойчивость к выбросам, нелинейные сочетания |
| Градиентный бустинг | Среднее | Средняя: важность, SHAP | Основной выбор для табличных данных |
| Нейронная сеть | Медленное | Низкая | Последовательности, тексты, очень большие объёмы |

### 3.3 Настройка и выбор модели

У каждой модели есть **гиперпараметры** — настройки, которые не определяются обучением (число деревьев, глубина, скорость обучения). Их подбирают по проверочной выборке; тестовую используют **один раз**, для итоговой оценки. Для временных данных вместо случайных блоков применяют последовательность временных блоков: обучение предшествует проверке, между ними зазор.

Сл. 15

На учебном наборе три модели с фиксированными настройками сравнены по **средней точности** (площадь под кривой «точность — полнота», определение в главе 4) и по ROC-AUC (таблица 7). Логистическая регрессия имеет наибольшее значение ROC-AUC, случайный лес — наибольшее значение средней точности.

Таблица 7 — Три модели на учебном наборе (AP — средняя точность)

| Модель | AP, проверка | AP, тест | ROC-AUC, проверка | ROC-AUC, тест |
|---|---|---|---|---|
| Логистическая регрессия | 0,156 | 0,118 | 0,882 | 0,883 |
| Случайный лес | 0,503 | 0,337 | 0,754 | 0,622 |
| Градиентный бустинг | 0,337 | 0,005 | 0,656 | 0,430 |

У случайного ответа средняя точность равна доле атак, около 0,005, поэтому на тестовой выборке градиентный бустинг не превосходит случайного выбора (ROC-AUC 0,430 ниже 0,5), хотя на проверочной выборке занимал второе место. Устойчивость вывода проверяется по трём временным блокам (таблица 8).

Таблица 8 — Средняя точность по временным блокам

| Блок (обучение → проверка) | Дни 1–20 → 22–28 | Дни 1–27 → 29–35 | Дни 1–34 → 36–45 |
|---|---|---|---|
| Атак в проверке | 2 | 4 | 6 |
| Логистическая регрессия | 0,502 | 0,277 | 0,156 |
| Случайный лес | 0,502 | 0,752 | 0,503 |
| Градиентный бустинг | 0,502 | 0,752 | 0,337 |

Сл. 16

Порядок моделей меняется от блока к блоку; в блоке из двух атак все три модели дают одно значение. Атак недостаточно для надёжного различения моделей. Следовательно, модели следует оценивать по нескольким временным блокам, не выбирать по различию в несколько сотых и при близких результатах предпочитать более простую. Далее рассматривается логистическая регрессия.

## 4 Метрики и выбор порога

### 4.1 Исходы и метрики

Сл. 18

Каждый объект при проверке оказывается в одной из четырёх ячеек (таблица 9): TP (верное срабатывание: атака и сигнал), FP (ложное срабатывание: сигнал без атаки), FN (пропуск: атака без сигнала) и TN (верное молчание).

Таблица 9 — Исходы классификации

| | **Атака была** | **Атаки не было** |
|---|---|---|
| **Сигнал есть** | TP | FP |
| **Сигнала нет** | FN | TN |

Сл. 19

**Точность** (Precision) показывает, какая доля сигналов оказалась атакой; **полнота** (Recall) — какая доля атак найдена:

$$\mathrm{Precision} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}, \quad \mathrm{Recall} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}. \tag{2}$$

Эти величины изменяются в противоположных направлениях: чем выше порог, тем меньше ложных сигналов (точность растёт) и тем больше пропусков (полнота падает). Чтобы сравнивать пороги и модели одним числом, точность и полноту объединяют в **F-меру**. Параметр $\beta$ показывает, во сколько раз полнота важнее точности:

Сл. 20

$$F_\beta = (1 + \beta^2) \cdot \frac{\mathrm{Precision} \cdot \mathrm{Recall}}{\beta^2 \cdot \mathrm{Precision} + \mathrm{Recall}}. \tag{3}$$

При $\beta = 1$ точность и полнота равнозначны (F1 — среднее гармоническое двух величин). При $\beta = 2$ полнота в два раза важнее точности (F2): такое значение выбирают, когда пропуск атаки обходится дороже ложной тревоги. При $\beta = 0\{,\}5$ вдвое важнее точность (F0,5): его выбирают, когда разбор каждого ложного сигнала дорог. Влияние параметра показывает условный пример двух моделей с зеркальными свойствами (таблица 10): значения F1 у них совпадают, а F2 и F0,5 предпочитают разные модели.

Таблица 10 — Влияние параметра $\beta$ на выбор (условный пример)

| Модель | Precision | Recall | F1 | F2 | F0,5 |
|---|---|---|---|---|---|
| A: мало ложных тревог, много пропусков | 0,9 | 0,3 | 0,450 | 0,346 | **0,643** |
| B: мало пропусков, много ложных тревог | 0,3 | 0,9 | 0,450 | **0,643** | 0,346 |

Следовательно, параметр нельзя выбирать произвольно: он отражает соотношение стоимости пропуска и ложной тревоги. На учебном наборе при пороге 0,612 (проверочная выборка) F1 равна 0,348, а F2 — 0,488: полнота этого порога (0,667) выше его точности (0,235), поэтому F2 оказывается больше F1.

### 4.2 Кривая «точность — полнота» и ROC-кривая

Сл. 21

Метрики при одном пороге зависят от выбранного порога. Чтобы сравнивать модели независимо от него, рассматривают всю совокупность порогов. **Кривой «точность — полнота»** называется график, на котором каждому значению порога соответствует точка с координатами (полнота, точность). Порог последовательно понижают от наибольшей оценки к наименьшей; для каждого значения полнота и точность вычисляются по объектам, оценка которых не ниже порога. При понижении порога полнота не убывает, а точность изменяется нерегулярно: в сигналы начинают попадать нормальные объекты. Площадь под кривой называют **средней точностью** (Average Precision, AP); она вычисляется как сумма

$$\mathrm{AP} = \sum_{n} (R_n - R_{n-1}) \cdot P_n, \tag{4}$$

где $P_n$ и $R_n$ — точность и полнота при $n$-м пороге. Значение AP тем больше, чем выше точность сохраняется при росте полноты; у случайного ответа оно равно доле атак.

Часто применяют и **ROC-кривую**: на ней при тех же порогах откладывается полнота (доля верных срабатываний) в зависимости от доли ложных срабатываний $\frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}}$; площадь под ней обозначают ROC-AUC, у случайного ответа она равна 0,5. Обе кривые для логистической регрессии учебного набора на тестовой выборке показаны на рисунке 4.

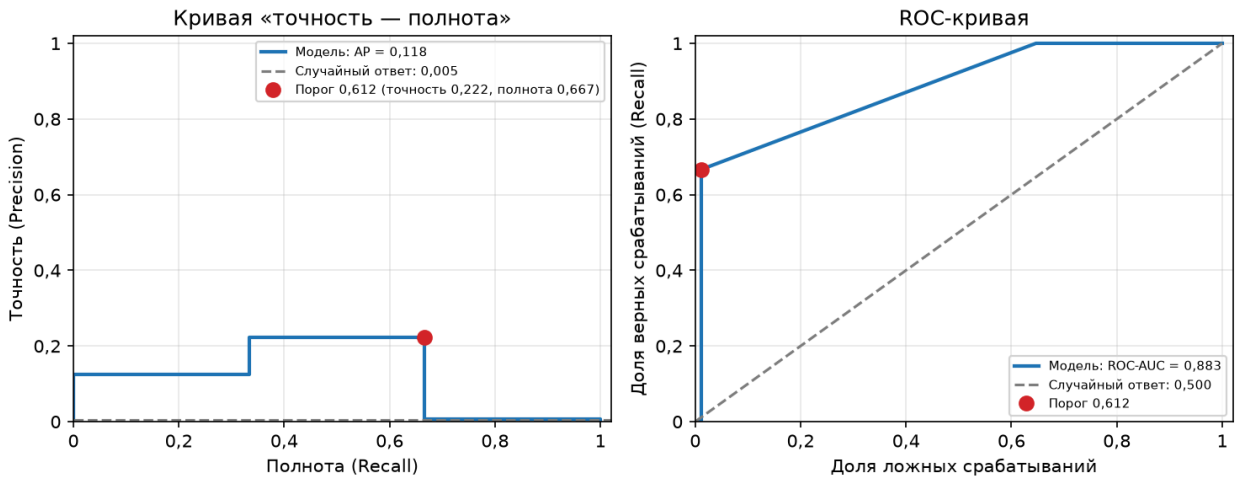



Рисунок 4 — Кривая «точность — полнота» и ROC-кривая логистической регрессии (тестовая выборка)

На левом графике кривая лежит существенно выше случайного уровня 0,005, но низко в абсолютном выражении: средняя точность равна 0,118. Ступенчатая форма объясняется тем, что модель присваивает объектам лишь несколько различных оценок. Красная точка отмечает порог 0,612: точность 0,222 при полноте 0,667. На правом графике та же модель выглядит благополучно (ROC-AUC равен 0,883), а выбранному порогу соответствует доля ложных срабатываний лишь 14 / 1 211 = 0,012. При сильном дисбалансе ROC-AUC завышает оценку качества, поскольку доля ложных срабатываний вычисляется относительно очень большого числа нормальных объектов и остаётся малой даже при сотнях ложных сигналов [8]. Поэтому при редких атаках основной метрикой выбирают среднюю точность (таблица 7), а ROC-AUC рассматривают как вспомогательную.

### 4.3 Выбор порога

Сл. 22

Стандартная граница 0,5 редко подходит. Выбор порога — отдельное решение, которое принимается по проверочной выборке и затем фиксируется [9]. Порог определяет, сколько объектов превратится в сигналы: чем он ниже, тем больше сигналов и тем больше атак среди них. Зависимость для оценок логистической регрессии на проверочной выборке показана в таблице 11. Каждая строка соответствует одному порогу; число сигналов пересчитано в сутки (проверочная выборка охватывает десять суток); в проверочной выборке шесть атак, поэтому наибольшее возможное число верных срабатываний (TP) равно шести; последний столбец показывает, сколько атак обнаружено при данном пороге.

Таблица 11 — Порог, нагрузка и число обнаруженных атак (проверочная выборка)

| **Порог** | **Сигналов в сутки** | **Атак в выборке (наибольшее возможное TP)** | **Обнаружено атак (TP)** |
|---|---|---|---|
| 0,3 | 81 | 6 | 6 |
| 0,5 | 1,7 | 6 | 4 |
| 0,7 | 1,6 | 6 | 3 |
| 0,8 | 1,2 | 6 | 2 |
| 0,99 | 1,1 | 6 | 1 |

Из таблицы следуют два вывода. Во-первых, при пороге 0,3 найдены все шесть атак, но аналитик получал бы около 81 сигнала в сутки, а доля верных сигналов составляла бы лишь 0,7 %: такой объём превышает возможности анализа. Во-вторых, при пороге 0,5 поток составляет менее двух сигналов в сутки, и обнаружены четыре атаки из шести; при дальнейшем повышении порога число обнаруженных атак падает, а нагрузка почти не снижается. На тестовой выборке при тех же порогах обнаружено 6, 4, 2, 0 и 0 атак из шести при 79, 1,8, 1,6, 1,0 и 1,0 сигнала в сутки: при пороге 0,8 и выше атак не обнаруживается вовсе, то есть высокая оценка не гарантирует атаку.

Критерии выбора порога перечислены в таблице 12; все они используют только проверочную выборку.

Таблица 12 — Критерии выбора порога

| **Критерий** | **Что максимизируется или минимизируется** | **Когда применяют** |
|---|---|---|
| F-мера | $F_\beta$ при выбранном $\beta$ | Нужен баланс точности и полноты |
| Суммарная стоимость | $C_{\mathrm{FP}} \cdot \mathrm{FP} + C_{\mathrm{FN}} \cdot \mathrm{FN}$ [10] | Известна стоимость ложной тревоги и пропуска |
| Нагрузка аналитиков | Полнота при ограничении числа сигналов в сутки | Ограничен ресурс разбора |

В учебном наборе F2 на проверочной выборке максимальна при пороге 0,612 (значение 0,488), и тот же порог минимизирует стоимость при $C_{\mathrm{FN}} = 50 \cdot C_{\mathrm{FP}}$ (суммарная стоимость 113). Три критерия дали один порог потому, что оценки логистической регрессии принимают лишь несколько различных значений: большинство объектов — окна с одной попыткой входа и одинаковыми признаками, поэтому они получают одну и ту же оценку. На тесте порог 0,612 даёт 18 сигналов: 4 верных, 14 ложных, 2 пропущенных атаки (точность 0,222, полнота 0,667, F1 равна 0,333). Тестовая выборка при этом

использована один раз, для оценки; подбор порога по результатам теста был бы утечкой.

### 4.4 Правила передачи на анализ

Один порог превращает оценку в бинарное решение. На практике оценку делят на зоны, для каждой из которых задаётся своё действие: низкие оценки не передаются, средние попадают в очередь разбора, высокие порождают срочное уведомление. Границы зон определяют по проверочной выборке так, чтобы доля верных сигналов в зоне соответствовала ожиданиям. Для учебного набора зоны и их фактическое содержание приведены в таблице 13.

Таблица 13 — Зоны оценки и их содержание

| Зона оценки | Проверка: сигналов | Проверка: атак | Тест: сигналов | Тест: атак |
|---|---|---|---|---|
| Ниже 0,612: не передавать | 1 198 | 2 | 1 199 | 2 |
| 0,612–0,9: очередь разбора | 5 | 2 | 8 | 4 |
| 0,9 и выше: срочный сигнал | 12 | 2 | 10 | 0 |

Пример показателен. На проверке и срочная, и обычная зоны содержат по две атаки, а на тесте срочная зона не содержит ни одной: оценка выше 0,9 здесь не означает большую уверенность. Следствие: границы зон нельзя назначать по виду оценки, их необходимо проверять на нескольких временных блоках, а автоматические действия по одной лишь оценке без участия человека допустимы только там, где точность зоны подтверждена.

Две пропущенные атаки теста — это окна с единственным успешным входом после подбора: числа попыток и неудач в таком окне не отличаются от обычного входа, и никакой порог их не выделит. Это ограничение признаков, а не порога: недостающую информацию должны давать новые признаки (например, успешный вход после серии неудач с того же адреса) или правило обнаружения.

## 5 Интерпретация модели

### 5.1 Зачем объяснять решения

Объяснение решений модели необходимо для четырёх целей: аналитик должен понимать причину формирования сигнала; анализ ложных срабатываний и пропусков определяет, какие изменения требуются в признаках и правилах; владелец сервиса и аудитор нуждаются в обосновании; наконец, объяснение является основным средством выявления ошибок построения модели. Неправдоподобно высокая важность признака, как правило, свидетельствует об утечке данных или о связи, отсутствующей в условиях эксплуатации.

### 5.2 Веса признаков линейной модели

Сл. 24

В логистической регрессии объяснение содержится в весах, если признаки приведены к одному масштабу (таблица 14).

Таблица 14 — Веса логистической регрессии

| Признак | Вес | Как читать |
|---|---|---|
| Число попыток | +0,953 | Больше попыток — выше оценка |
| Доля неудач | −0,614 | При прочих равных выше доля неудач — ниже оценка |
| Число учётных записей | −0,311 | При прочих равных больше записей — ниже оценка |
| Ночной час | −2,326 | Ночные окна получают низкую оценку |

Интерпретировать веса по отдельности некорректно: признаки взаимосвязаны. Отрицательный вес доли неудач не означает, что неудачи безопасны: рост числа попыток уже увеличивает оценку, а вес доли лишь корректирует её. Вес ночного индикатора указывает на существенное ограничение: в учебных данных все атаки приходятся на дневное время, и модель восприняла отсутствие ночных атак в данных как закономерность. Для действий реальных нарушителей эта закономерность неверна и является ограничением модели, о котором должен быть осведомлён принимающий её в эксплуатацию.

### 5.3 Важность признаков перестановкой

Сл. 25

**Важностью перестановкой** называется снижение качества обученной модели после того, как значения одного признака случайно перемешаны между объектами. Перемешивание разрывает связь признака с ответом, а остальные признаки остаются прежними: если модель использовала этот признак, качество упадёт, если нет — останется прежним. Метод применим к любой модели, поскольку использует только её ответы. Вычисление выполняется по шагам (рисунок 5):

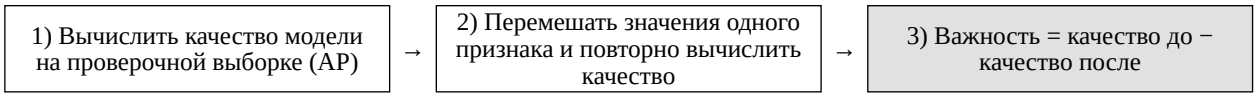



Рисунок 5 — Вычисление важности перестановкой

Перестановка случайна, поэтому её повторяют несколько раз (здесь 30) и вычисляют среднее и стандартное отклонение. Для логистической регрессии учебного набора качество на проверочной выборке до перемешивания равно 0,156 (средняя точность), а у случайного ответа — 0,005. Результаты по признакам приведены в таблице 15.

Таблица 15 — Важность признаков перестановкой (проверочная выборка)

| Признак | Качество после | Важность | Вывод |
|---|---|---|---|
| Число попыток | 0,006 | 0,150 ± 0,006 | Модель опирается на него: без него качество падает до случайного уровня |
| Число учётных записей | 0,123 | 0,033 ± 0,001 | Влияет слабо |
| Ночной час | 0,138 | 0,018 ± 0,052 | Неотличим от нуля: разброс больше значения |
| Доля неудач | 0,312 | −0,156 ± 0,053 | Мешает: после перемешивания качество выше |

Значение близкое к нулю означает, что модель практически не использует признак. Значение, не превышающее разброс (ночной час), нельзя отличать от нуля. Отрицательное значение означает, что на проверочной выборке признак не повышает, а снижает качество модели: его связь с ответом, выученная на обучающей выборке, не подтверждается на проверочной. Такой результат служит основанием для пересмотра набора признаков. Важность нужно оценивать на данных, не использованных при обучении, и с осторожностью — для связанных между собой признаков она распределяется между ними.

### 5.4 Значения SHAP

Сл. 26

Метод SHAP объясняет ответ модели для конкретного объекта, разлагая его на вклады признаков. Он основан на **значениях Шепли** из теории кооперативных игр [11]: признаки рассматриваются как участники игры, а «выигрышем» служит ответ модели. Вклад признака — это среднее изменение ответа модели при добавлении этого признака к некоторому набору остальных признаков, усреднённое по всем возможным наборам и порядкам их добавления. Значения Шепли обладают свойством локальной точности: базовое значение (средний ответ модели на фоновых данных) плюс сумма вкладов всех признаков в точности равны ответу модели для объекта. Положительный вклад повышает оценку, отрицательный — понижает.

Точное вычисление требует перебора подмножеств признаков и для произвольной модели трудоёмко. Для линейных моделей вклады вычисляются по формуле, а для ансамблей деревьев существует быстрый точный алгоритм [12], поэтому SHAP особенно удобен для градиентного бустинга и случайного леса. Для логистической регрессии вклады выражены в шкале логарифма шансов; итоговая сумма преобразуется в оценку логистической функцией $\frac{1}{1+e^{-z}}$.

Пример на учебном наборе показан в таблице 16 и на рисунке 6: сравниваются настоящая атака (распыление паролей) и ложная тревога, вызванная офисным пиком, когда много сотрудников входят в приложение с одного адреса.

Таблица 16 — Вклады признаков в оценку двух объектов (тестовая выборка)

| Вклад | Атака (распыление) | Ложная тревога (офисный пик) |
|---|---|---|
| Базовое значение | −2,04 | −2,04 |
| Число попыток | +4,64 | +8,85 |
| Доля неудач | −1,67 | +0,09 |
| Число учётных записей | −1,72 | −3,05 |
| Ночной час | +1,24 | +1,24 |
| Сумма (логарифм шансов) | 0,46 | 5,09 |
| Оценка модели | 0,612 | 0,994 |

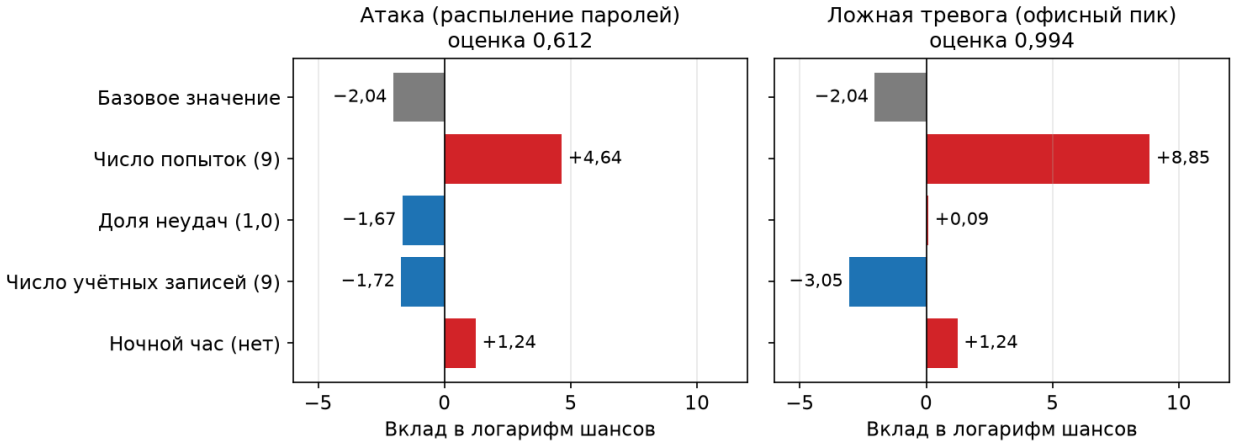



Рисунок 6 — Вклады признаков: красные повышают оценку, синие понижают

Для атаки оценку повышает число попыток, а число учётных записей и доля неудач её понижают. Для офисного пика основной вклад (+8,85) даёт число попыток: оно настолько велико, что вклад других признаков не меняет итог, и оценка 0,994 выше, чем у настоящей атаки. Причина видна из таблицы: вес доли неудач в модели отрицателен, поэтому низкая доля неудач, которая отличает обычный вход от перебора, не снижает оценку офисного пика (вклад +0,09). Так объяснение показывает конкретный дефект модели и направление исправления: ввести признак, отделяющий массовый вход многих пользователей от перебора.

Результаты SHAP по всему набору представляют диаграммами трёх видов: диаграмма «сил» показывает разложение для одного объекта, сводная диаграмма — распределение вкладов каждого признака по набору, диаграмма зависимости — связь значения признака с его вкладом. SHAP описывает вклад признака в ответ модели относительно фона, а не причинную связь.

Сл. 27

Важность перестановкой и SHAP отвечают на разные вопросы. Важность перестановкой отвечает на вопрос: «насколько модель пострадает без этого признака?» SHAP отвечает на вопрос: «что именно этот признак сделал с оценкой этого объекта?» Различия по свойствам сведены в таблице 17.

Таблица 17 — Важность перестановкой и SHAP

| Свойство | Важность перестановкой | SHAP |
|---|---|---|
| Что делает | Перемешивает значения признака и измеряет падение качества | Раскладывает ответ модели на вклады признаков |
| Для чего вычисляется | Для всей выборки: одно число на признак | Для каждого объекта отдельно |
| Что показывает | Полезность признака для качества (AP) | Влияние признака на ответ модели |
| Нужны ли правильные ответы | Да: без них качество не вычислить | Нет: достаточно модели и данных |
| Как читать знак | Падение — признак важен, около нуля — не используется, меньше нуля — мешает | Плюс повышает оценку, минус понижает |

Различие видно на примере ночного часа: он вносит заметный вклад (+1,24) в оценку почти всех дневных объектов, поскольку на фоне входит часть ночных объектов, но этот вклад практически одинаков для всех дневных объектов и не помогает отличать атаки от нормы. Поэтому важность перестановкой для него близка к нулю, тогда как в SHAP вклад заметен.

# 6 Эксплуатация и паспорт модели

## 6.1 Конвейер модели

Сл. 29

Обученная модель становится частью системы мониторинга (рисунок 7): признаки вычисляются по потоку событий, модель оценивает объекты, порог и зоны превращают оценки в сигналы, а аналитик их разбирает. Параллельно работают мониторинг качества и реестр версий моделей.

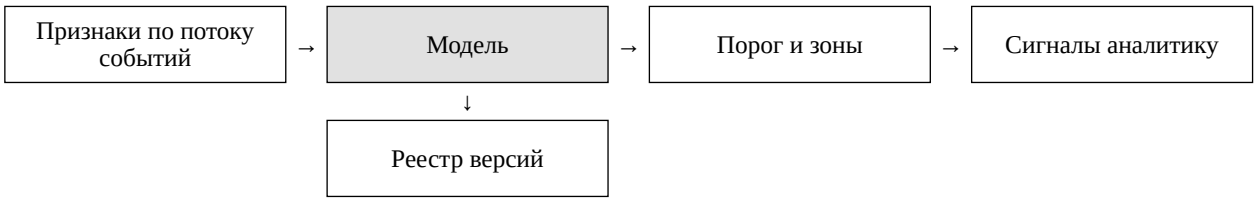



Рисунок 7 — Модель в системе мониторинга

## 6.2 Требования к эксплуатации

Сл. 30

Модель в эксплуатации требует тех же свойств, что любая промышленная система (таблица 18).

Таблица 18 — Требования к эксплуатации модели

| Требование | Содержание | Примеры средств |
|---|---|---|
| Воспроизводимость | Повторимое обучение: зафиксированы данные, версии библиотек, случайные начальные значения | MLflow, DVC |
| Версионирование | Версии модели, данных и признаков связаны с порогом | Реестр моделей |
| Задержка | Время оценки укладывается в требования реагирования | Пакетная обработка |
| Мониторинг | Контроль качества и сдвига входных данных | Prometheus, Grafana, Evidently |
| Откат | Быстрый возврат к предыдущей версии | Поэтапное развёртывание |
| Защита | Ограничен доступ к модели и порогу: нарушитель может подбирать способы обхода | Контроль доступа к интерфейсу |

Сл. 31

Режим обработки выбирают по допустимой задержке (таблица 19).

Таблица 19 — Режимы оценки

| Режим | Когда применяют | Пример |
|---|---|---|
| Пакетный (раз в несколько минут) | Допустима задержка, большой объём | Подбор пароля по пятиминутным окнам |
| Почти реальное время (секунды) | Нужна быстрая реакция | Обнаружение связи с управляющим сервером |
| Реальное время (по каждому событию) | Критичные системы, малый поток | Встроенный датчик |

### 6.3 Паспорт модели

Сл. 32

**Паспорт модели** (model card) — короткий документ, сопровождающий обученную модель: он описывает назначение модели, условия, в которых её можно применять, процедуру и результаты оценки [13]. Он нужен всем, кто принимает или использует модель: аналитикам, владельцам сервиса, аудиторам. Разделы паспорта приведены в таблице 20.

Таблица 20 — Разделы паспорта модели

| Раздел | Содержание |
|---|---|
| Сведения о модели | Алгоритм, версия, дата обучения, автор |
| Назначение | Для чего модель предназначена и для чего нет |
| Данные обучения | Источник, период, объём, доля атак, признаки |
| Данные оценки | Разбиение по времени, границы выборок |
| Метрики | Средняя точность, точность и полнота при выбранном пороге |
| Порог | Значение, метод выбора, обоснование |
| Ограничения | Виды атак, не охваченные моделью; условия деградации; план переобучения |

Сл. 33

Для логистической регрессии учебного набора паспорт заполняется так (таблица 21).

Таблица 21 — Пример паспорта модели

| Раздел | Содержание |
|---|---|
| Сведения о модели | Логистическая регрессия с масштабированием признаков, веса классов «balanced»; четыре признака |
| Назначение | Оценка подозрительности адреса источника за пять минут по журналу входа. Не предназначена для обнаружения атак других видов |
| Данные обучения | Сутки 1–34, 4 116 объектов, 15 атак (подбор пароля и распыление паролей) |
| Данные оценки | Проверка — сутки 36–45 (6 атак), тест — сутки 47–56 (6 атак), зазоры — сутки 35 и 46 |
| Метрики на тесте | Средняя точность 0,118; при пороге: точность 0,222, полнота 0,667, F1 равна 0,333; 4 верных сигнала, 14 ложных, 2 пропуска |
| Порог | 0,612; выбран по F2 на проверочной выборке и совпал с минимумом стоимости при $C_{\mathrm{FN}} = 50 \cdot C_{\mathrm{FP}}$ |
| Ограничения | Мало атак (шесть на тест): результат нестабилен. Модель не обнаруживает окна с единственным успешным входом после подбора. Закономерность «ночью атак нет» выучена по данным. Переобучать при сдвиге данных и на каждом пересмотре признаков |

# ЗАКЛЮЧЕНИЕ

Сл. 34

Основные положения лекции собраны в таблице 22.

Таблица 22 — Основные положения лекции

| Глава | Главное |
|---|---|
| 1. Место модели | Модель дополняет правила; нужна, когда значимо сочетание признаков |
| 2. Дисбаланс | Accuracy при редких атаках не информативна; изменения числа примеров только в обучающей выборке |
| 3. Модели | Логистическая регрессия как база, ансамбли деревьев для табличных данных; выводы на малом числе атак неустойчивы |
| 4. Метрики и порог | Средняя точность; порог выбирается по проверочной выборке и фиксируется; зоны оценки проверяются на разных периодах |
| 5. Интерпретация | Веса и важность перестановкой, SHAP; объяснение помогает найти утечку и слепые пятна |
| 6. Эксплуатация | Воспроизводимость, мониторинг, откат; паспорт модели обязателен |

На практическом занятии 5 группа обучает и сравнивает модели на подготовленном наборе данных, выбирает порог по проверочной выборке, формулирует правила передачи сигналов на анализ и оформляет краткий паспорт модели.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ


1. Sommer R., Paxson V. Outside the Closed World: On Using Machine Learning for Network Intrusion Detection // Proceedings of the IEEE Symposium on Security and Privacy. 2010. Сс. 305–316.
2. Arp D. и др. Dos and Don'ts of Machine Learning in Computer Security // Proceedings of the 31st USENIX Security Symposium. 2022. Сс. 3971–3988.
3. Chawla N. V. и др. SMOTE: Synthetic Minority Over-sampling Technique // Journal of Artificial Intelligence Research. 2002. Т. 16. Сс. 321–357.
4. scikit-learn developers. Common pitfalls and recommended practices. scikit-learn User Guide [Электронный ресурс]. 2025. URL: https://scikit-learn.org/stable/common_pitfalls.html.
5. Breiman L. Random Forests // Machine Learning. 2001. Т. 45, № 1. Сс. 5–32.
6. Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. 2001. Т. 29, № 5. Сс. 1189–1232.
7. Grinsztajn L., Oyallon E., Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data? // Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track. 2022.
8. Saito T., Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets // PLOS ONE. 2015. Т. 10, № 3. С. e0118432.
9. scikit-learn developers. Tuning the decision threshold for class prediction. scikit-learn User Guide [Электронный ресурс]. 2025. URL: https://scikit-learn.org/stable/modules/classification_threshold.html.
10. Elkan C. The Foundations of Cost-Sensitive Learning // Proceedings of the 17th International Joint Conference on Artificial Intelligence. 2001. Сс. 973–978.
11. Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // Advances in Neural Information Processing Systems 30. 2017.
12. Lundberg S. M. и др. From local explanations to global understanding with explainable AI for trees // Nature Machine Intelligence. 2020. Т. 2, № 1. Сс. 56–67.

13. Mitchell M. и др. Model Cards for Model Reporting // Proceedings of the Conference on Fairness, Accountability, and Transparency. 2019. Сс. 220–229.

## ПРИЛОЖЕНИЕ А

Вопросы для самопроверки

Каждый вопрос сопровождается кратким ответом, составленным по материалу лекции.

**1. Почему Accuracy не подходит при дисбалансе классов?**

*Ответ.* Модель, выдающая для любого объекта ответ «норма», на тестовой выборке учебного набора имеет Accuracy 0,995, но не обнаруживает ни одной атаки. Accuracy определяется числом нормальных объектов и скрывает пропуски и ложные срабатывания.

**2. Чем средняя точность предпочтительнее ROC-AUC при редких атаках?**

*Ответ.* ROC-AUC использует долю ложных срабатываний относительно всех нормальных объектов и остаётся высокой даже при сотнях ложных сигналов. Средняя точность учитывает точность сигналов и чувствительна к редкому классу. У логистической регрессии учебного набора ROC-AUC равен 0,883, а средняя точность — 0,118.

**3. Чем F1, F2 и F0,5 отличаются и когда какую применять?**

*Ответ.* F-мера объединяет точность и полноту; параметр $\beta$ задаёт вес полноты. F1 даёт равный вес, F2 усиливает полноту (применяется, когда пропуск атаки дороже ложной тревоги), F0,5 усиливает точность (когда дорого разбирать ложные сигналы).

**4. Как выбирают порог срабатывания?**

*Ответ.* По проверочной выборке одним из критериев: максимум F-меры, минимум суммарной стоимости ($C_{\mathrm{FP}} \cdot \mathrm{FP} + C_{\mathrm{FN}} \cdot \mathrm{FN}$) или максимум полноты при ограничении числа сигналов в сутки. Порог фиксируется и затем один раз проверяется на тесте; подбор порога по тесту является утечкой.

**5. Почему число, которое выдаёт модель с весами классов, нельзя читать как вероятность?**

*Ответ.* Веса классов сознательно повышают значимость редкого класса, и выдаваемая оценка смещена вверх относительно реальной вероятности. Её

используют для упорядочения объектов; границу решения определяет порог, выбранный по данным.

**6. Какую модель следует принять в качестве первой и почему?**

*Ответ.* В качестве базовой принимают логистическую регрессию: она быстро обучается и допускает простое объяснение, а более сложная модель должна продемонстрировать улучшение. Для табличных данных среднего размера основной выбор — ансамбли деревьев (случайный лес, градиентный бустинг). Нейронные сети для таких данных в качестве первого выбора не рассматриваются.

**7. Почему сравнение моделей на учебном наборе нельзя считать надёжным?**

*Ответ.* В проверке и тесте по шесть атак, и порядок моделей меняется от одного временного блока к другому; в блоке из двух атак три модели дают одинаковый результат. Модели нужно сравнивать по нескольким временным блокам и при близких результатах предпочитать более простую.

**8. Что показывает важность признака перестановкой и как читать отрицательное значение?**

*Ответ.* Она показывает, насколько ухудшается качество при перемешивании значений признака. Отрицательное значение (доля неудач: −0,156) означает, что признак на проверке не помогает, а вносит случайную составляющую; основание для пересмотра набора признаков.

**9. Какие разделы должен содержать паспорт модели?**

*Ответ.* Сведения о модели, назначение (в том числе для чего она не годится), данные обучения, данные оценки, метрики, порог с обоснованием и ограничения. Паспорт нужен аналитикам, владельцам сервиса и аудиторам, чтобы модель не применяли вне условий, для которых она оценена.

**10. Почему граница «срочной» зоны оценки не должна задаваться по виду оценки?**

*Ответ.* В примере зона оценок выше 0,9 на проверке содержала две атаки, а на тесте ни одной. Границы зон нужно проверять на нескольких временных блоках, а автоматические действия по самой оценке допускать лишь там, где точность зоны подтверждена.