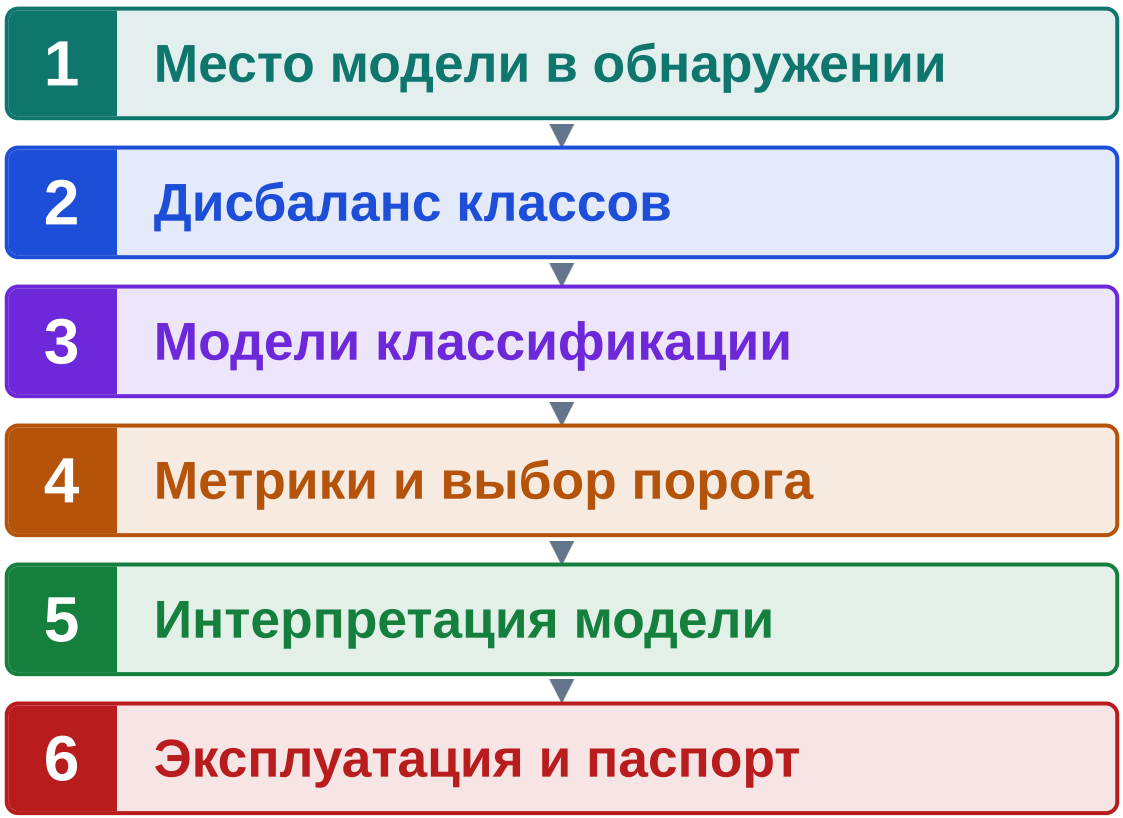
Методы и принципы проектирования современных защищённых систем

Лекция 5

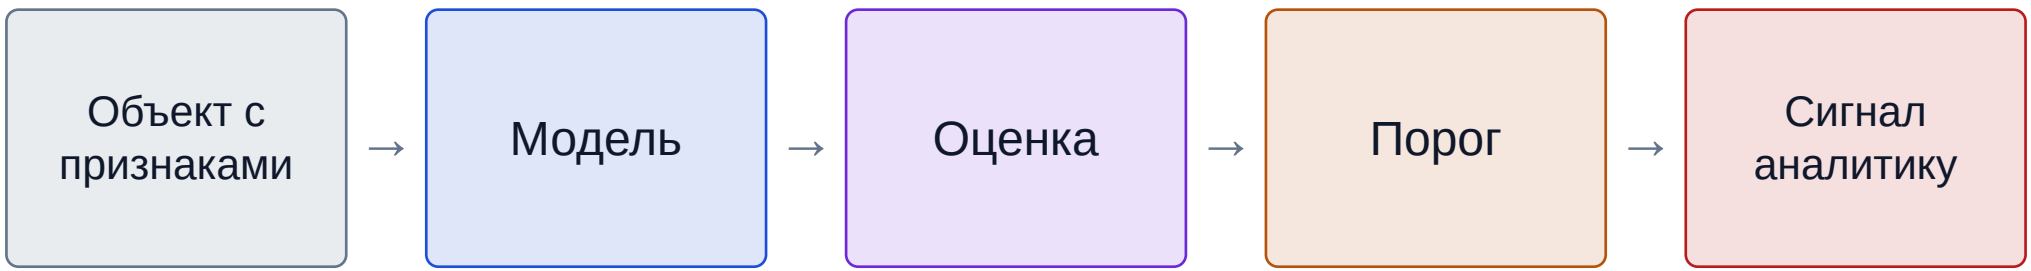
Модели классификации для обнаружения инцидентов

Дисбаланс классов · метрики · порог · интерпретация

План лекции


1
Место модели в обнаружении
2
Дисбаланс классов
3
Модели классификации
4
Метрики и выбор порога
5
Интерпретация модели
6
Эксплуатация и паспорт

От объекта к сигналу



Качество определяют два решения: какая модель и где порог

1

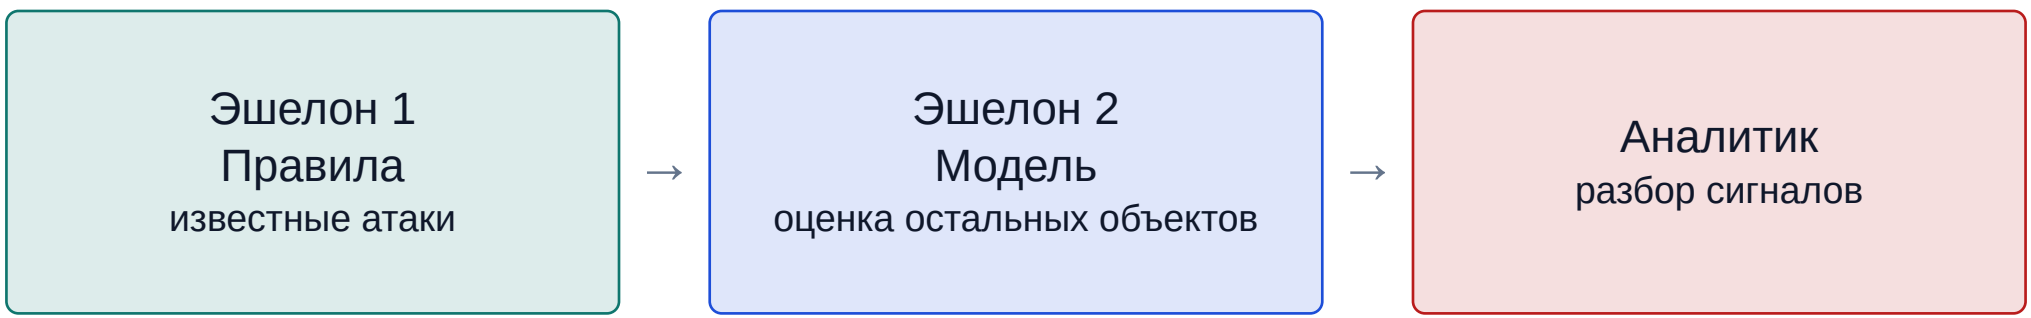
Место модели в обнаружении

когда нужна модель, а не правило

Правило или модель

Условие задачи	Правило	Модель
Атаку описывает одно пороговое условие	Подходит	Избыточна
Значимо сочетание многих слабых признаков	Трудно записать	Подходит
Нет размеченных примеров атак	Подходит	Не обучить
Нужно обосновать каждое решение	Подходит	Интерпретируемая модель
Нет мониторинга и переобучения	Подходит	Качество деградирует

Три эшелона



Модель дополняет правила, а не заменяет их

Учебный набор данных

4 116

объектов в обучении · 15 атак

1 215

в проверке · 6 атак

1 217

в тесте · 6 атак

Объект: адрес источника за пять минут

Признаки: попытки, доля неудач, учётные записи, ночь

Разбиение по времени; сутки 35 и 46 — зазоры

2

Дисбаланс классов

атак мало, нормы очень много

Accuracy при дисбалансе

Тестовая выборка: 1 217 объектов

1 211 нормальных

6 атак · 0,49 %

Показатель	Всегда «норма»	Логистическая регрессия
Найдено атак	0 из 6	**4 из 6**
Accuracy	**0,995**	0,987
Recall	0,000	**0,667**
Precision	—	**0,222**
F1	0,000	**0,333**
Сбалансированная Accuracy	0,500	**0,828**

По Accuracy побеждает модель, которая не находит ни одной атаки

Методы работы с дисбалансом

Меньше нормы	Больше атак	Веса классов	Порог
сохраняет реальные данные, теряет информацию	копии или синтетика; новых видов атак нет	ошибка на атаке весит больше; данные не меняются	выбор по проверочной выборке вместо 0,5

Рекомендуемый порядок

1 · Веса классов → 2 · Порог по проверочной выборке → 3 · Изменение числа примеров в обучении

Изменять число примеров можно только в обучающей выборке; оценка модели с весами — не вероятность

3

Модели классификации

какую модель взять и как сравнить

Логистическая регрессия и ансамбли

Логистическая регрессия	Случайный лес	Градиентный бустинг	Нейронная сеть
сумма признаков с весами; базовая модель	независимые деревья, усреднение	каждое дерево исправляет ошибки предыдущих	для последовательностей и очень больших объёмов

Сравнение моделей

Модель	Обучение	Объяснимость	Когда применять
Логистическая регрессия	Очень быстрое	Высокая: веса	Базовая модель
Случайный лес	Быстрое	Средняя	Нелинейные сочетания
Градиентный бустинг	Среднее	Средняя: SHAP	Основной выбор для таблиц
Нейронная сеть	Медленное	Низкая	Последовательности, тексты

Три модели на учебном наборе

Модель	AP, проверка	AP, тест	ROC-AUC, проверка	ROC-AUC, тест
Логистическая регрессия	0,156	0,118	**0,882**	**0,883**
Случайный лес	**0,503**	**0,337**	0,754	0,622
Градиентный бустинг	0,337	0,005	0,656	0,430

AP — средняя точность; у случайного ответа она равна доле атак, около 0,005

Средняя точность по временным блокам

Блок	Дни 1–20 → 22–28	Дни 1–27 → 29–35	Дни 1–34 → 36–45
Атак в проверке	2	4	6
Логистическая регрессия	0,502	0,277	0,156
Случайный лес	0,502	0,752	0,503
Градиентный бустинг	0,502	0,752	0,337

Порядок моделей меняется; атак мало — оценивать по нескольким блокам

4

Метрики и выбор порога

как оценить модель и где поставить границу

Четыре исхода

	Атака была	Атаки не было
Сигнал есть	**TP** верное срабатывание	**FP** ложное срабатывание
Сигнала нет	**FN** пропуск атаки	**TN** верное молчание

Точность и полнота

Точность (Precision)

$TP / (TP + FP)$

какая доля сигналов — атаки

Полнота (Recall)

$TP / (TP + FN)$

какая доля атак найдена

> Выше порог — меньше ложных сигналов, но больше пропусков

F-мера: параметр β задаёт вес полноты

$$F_\beta = \frac{(1+\beta^2)\cdot \text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}$$

β = 1 · F1
точность и полнота равнозначны

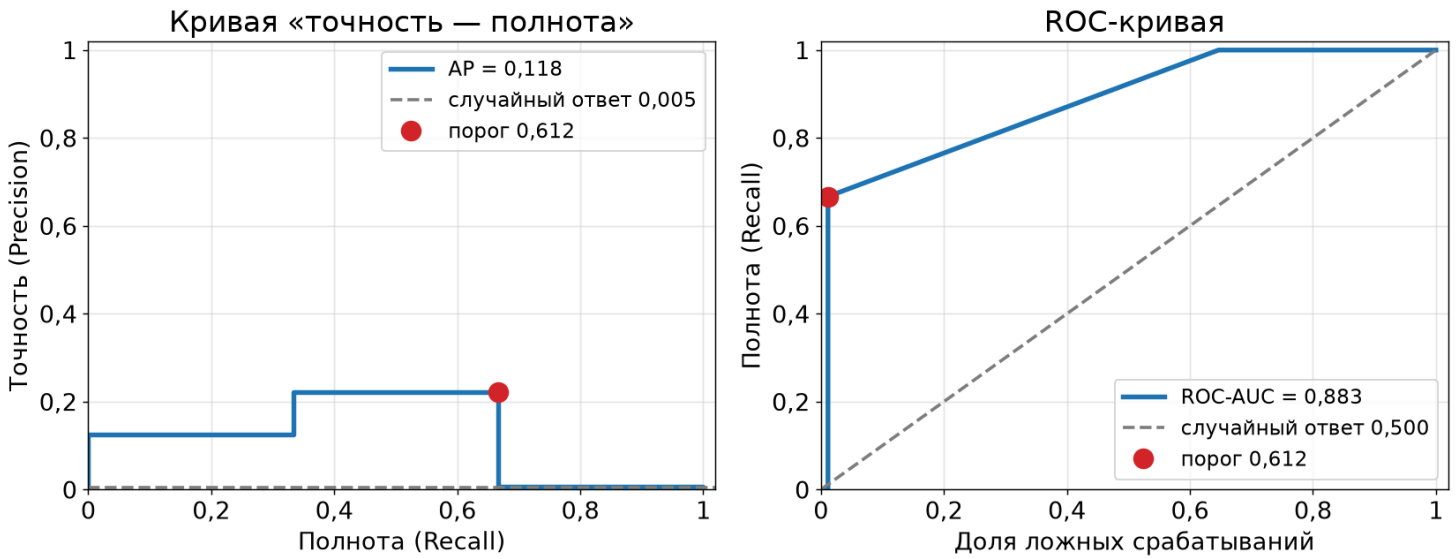
β = 2 · F2
полнота важнее: пропуск дороже

β = 0,5 · F0,5
точность важнее: ложные сигналы дороги

Условный пример	Precision	Recall	F1	F2	F0,5
A: мало ложных тревог, много пропусков	0,9	0,3	0,450	0,346	**0,643**
B: мало пропусков, много ложных тревог	0,3	0,9	0,450	**0,643**	0,346

F1 одинакова, но F2 выбирает модель B, а F0,5 — модель A

Кривая «точность — полнота» и ROC



AP = 0,118
случайный уровень 0,005

ROC-AUC = 0,883
выглядит благополучно

Порог 0,612
точность 0,222 · полнота 0,667

Кривая — все пороги сразу; при редких атаках ROC-AUC завышает качество

Порог: нагрузка и обнаруженные атаки

Проверочная выборка · десять суток · шесть атак

Порог	Сигналов в сутки	Атак в выборке (наибольшее TP)	Обнаружено атак (TP)
0,3	**81**	6	**6**
0,5	1,7	6	4
0,7	1,6	6	3
0,8	1,2	6	2
0,99	1,1	6	1

Ниже порог — больше сигналов и находок · на тесте при 0,8 и выше атак не обнаружено

5

Интерпретация модели

почему модель так решила

Веса логистической регрессии

Признак	Вес	Как читать
Число попыток	+0,953	больше попыток — выше оценка
Доля неудач	−0,614	при прочих равных — ниже оценка
Число учётных записей	−0,311	при прочих равных — ниже оценка
Ночной час	**−2,326**	ночные окна получают низкую оценку

В данных все атаки дневные: модель восприняла это как закономерность

Важность признаков перестановкой

1 · Качество модели
AP = 0,156

→

2 · Перемешать значения одного признака

→

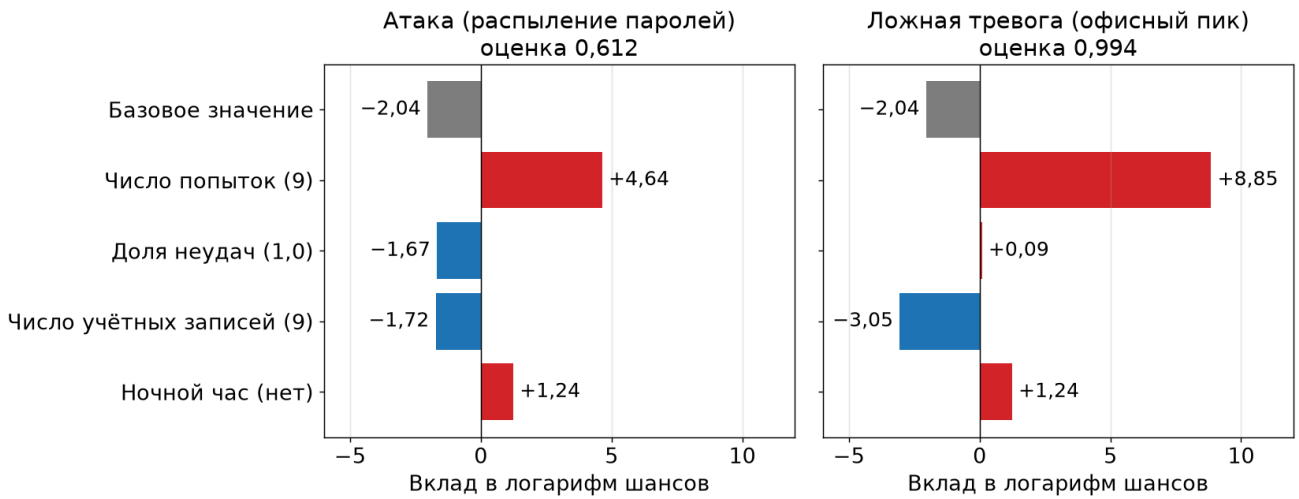
3 · Важность = качество до − качество после

Признак	AP после	Важность	Вывод
Число попыток	0,006	**0,150**	опирается: качество до случайного
Число учётных записей	0,123	0,033	влияет слабо
Ночной час	0,138	0,018 ± 0,052	неотличим от нуля
Доля неудач	**0,312**	**−0,156**	мешает: качество выросло

Важный признак: после перемешивания качество падает

Значения SHAP: из чего сложилась оценка

Базовое значение + вклады признаков = ответ модели · красные повышают оценку, синие понижают



Атака: число попыток повышает оценку, неудачи и записи понижают

Офисный пик: число попыток (+8,85) заглушает остальное

Перестановка и SHAP: в чём разница

Перестановка
«Насколько модель пострадает без этого признака?»

SHAP
«Что именно этот признак сделал с оценкой этого объекта?»

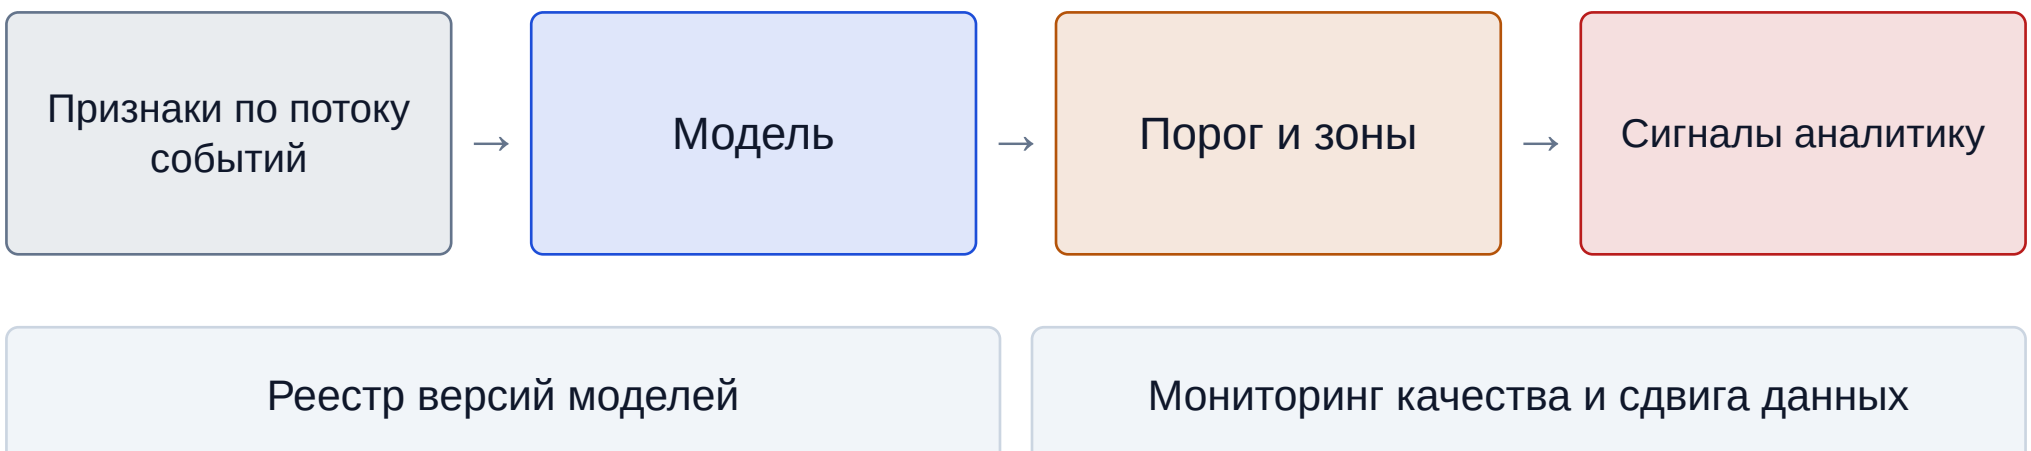
Свойство	Перестановка	SHAP
Что делает	Перемешивает значения признака, измеряет падение качества	Раскладывает ответ модели на вклады признаков
Для чего считает	Для всей выборки: одно число на признак	Для каждого объекта отдельно
Что показывает	Полезность признака для качества (AP)	Влияние признака на ответ модели
Нужны ли ответы	Да: без них качество не вычислить	Нет: достаточно модели и данных
Знак	Падение — важен; около 0 — не используется; меньше 0 — мешает	Плюс повышает оценку, минус понижает

6

Эксплуатация и паспорт

от модели к системе

Модель в системе мониторинга



Требования к эксплуатации

Воспроизводимость

данные, версии, начальные значения

Версионирование

модель, данные и признаки связаны с порогом

Задержка

укладывается в сроки реагирования

Мониторинг

качество и сдвиг входных данных

Откат

быстрый возврат к прежней версии

Защита

ограничен доступ к модели и порогу

Режимы оценки

Режим	Когда применяют	Пример
Пакетный	допустима задержка, большой объём	подбор пароля по окнам
Почти реальное время	нужна быстрая реакция	связь с управляющим сервером
Реальное время	критичные системы, малый поток	встроенный датчик

Паспорт модели

Сведения

алгоритм, версия, дата, автор

Назначение

для чего и для чего нет

Данные обучения

источник, период, доля атак

Данные оценки

границы выборок

Метрики

AP, точность, полнота

Порог

значение и обоснование

Ограничения

виды атак, деградация, переобучение

Пример паспорта

Раздел	Содержание
Модель	Логистическая регрессия, веса классов, четыре признака
Назначение	Оценка подозрительности источника за 5 минут по журналу входа
Обучение	Сутки 1–34: 4 116 объектов, 15 атак
Оценка	Проверка: сутки 36–45, тест: сутки 47–56, по 6 атак
Метрики, тест	AP 0,118; точность 0,222; полнота 0,667; F1 0,333
Порог	0,612: по F2 на проверке; совпал с минимумом стоимости
Ограничения	Мало атак; не находит одиночный вход после подбора; «ночью атак нет»

Главное

1 Место модели	Модель дополняет правила
2 Дисбаланс	Accuracy при редких атаках не информативна
3 Модели	База и ансамбли; атак мало — выводы неустойчивы
4 Метрики и порог	Средняя точность; порог по проверке
5 Интерпретация	Веса, перестановка, SHAP — ищем ошибки
6 Эксплуатация	Воспроизводимость, мониторинг, паспорт

Методы и принципы проектирования современных защищённых систем

Лекция 5

Модели классификации для обнаружения инцидентов

Дисбаланс классов · метрики · порог · интерпретация